神经网络

周沫凡

博士

悉尼科技大学, 格里菲斯大学


ALPHAGO
02:00:00
LEE SEDOL
01:59:31
Googl
AlphaGo
Lee Sedol

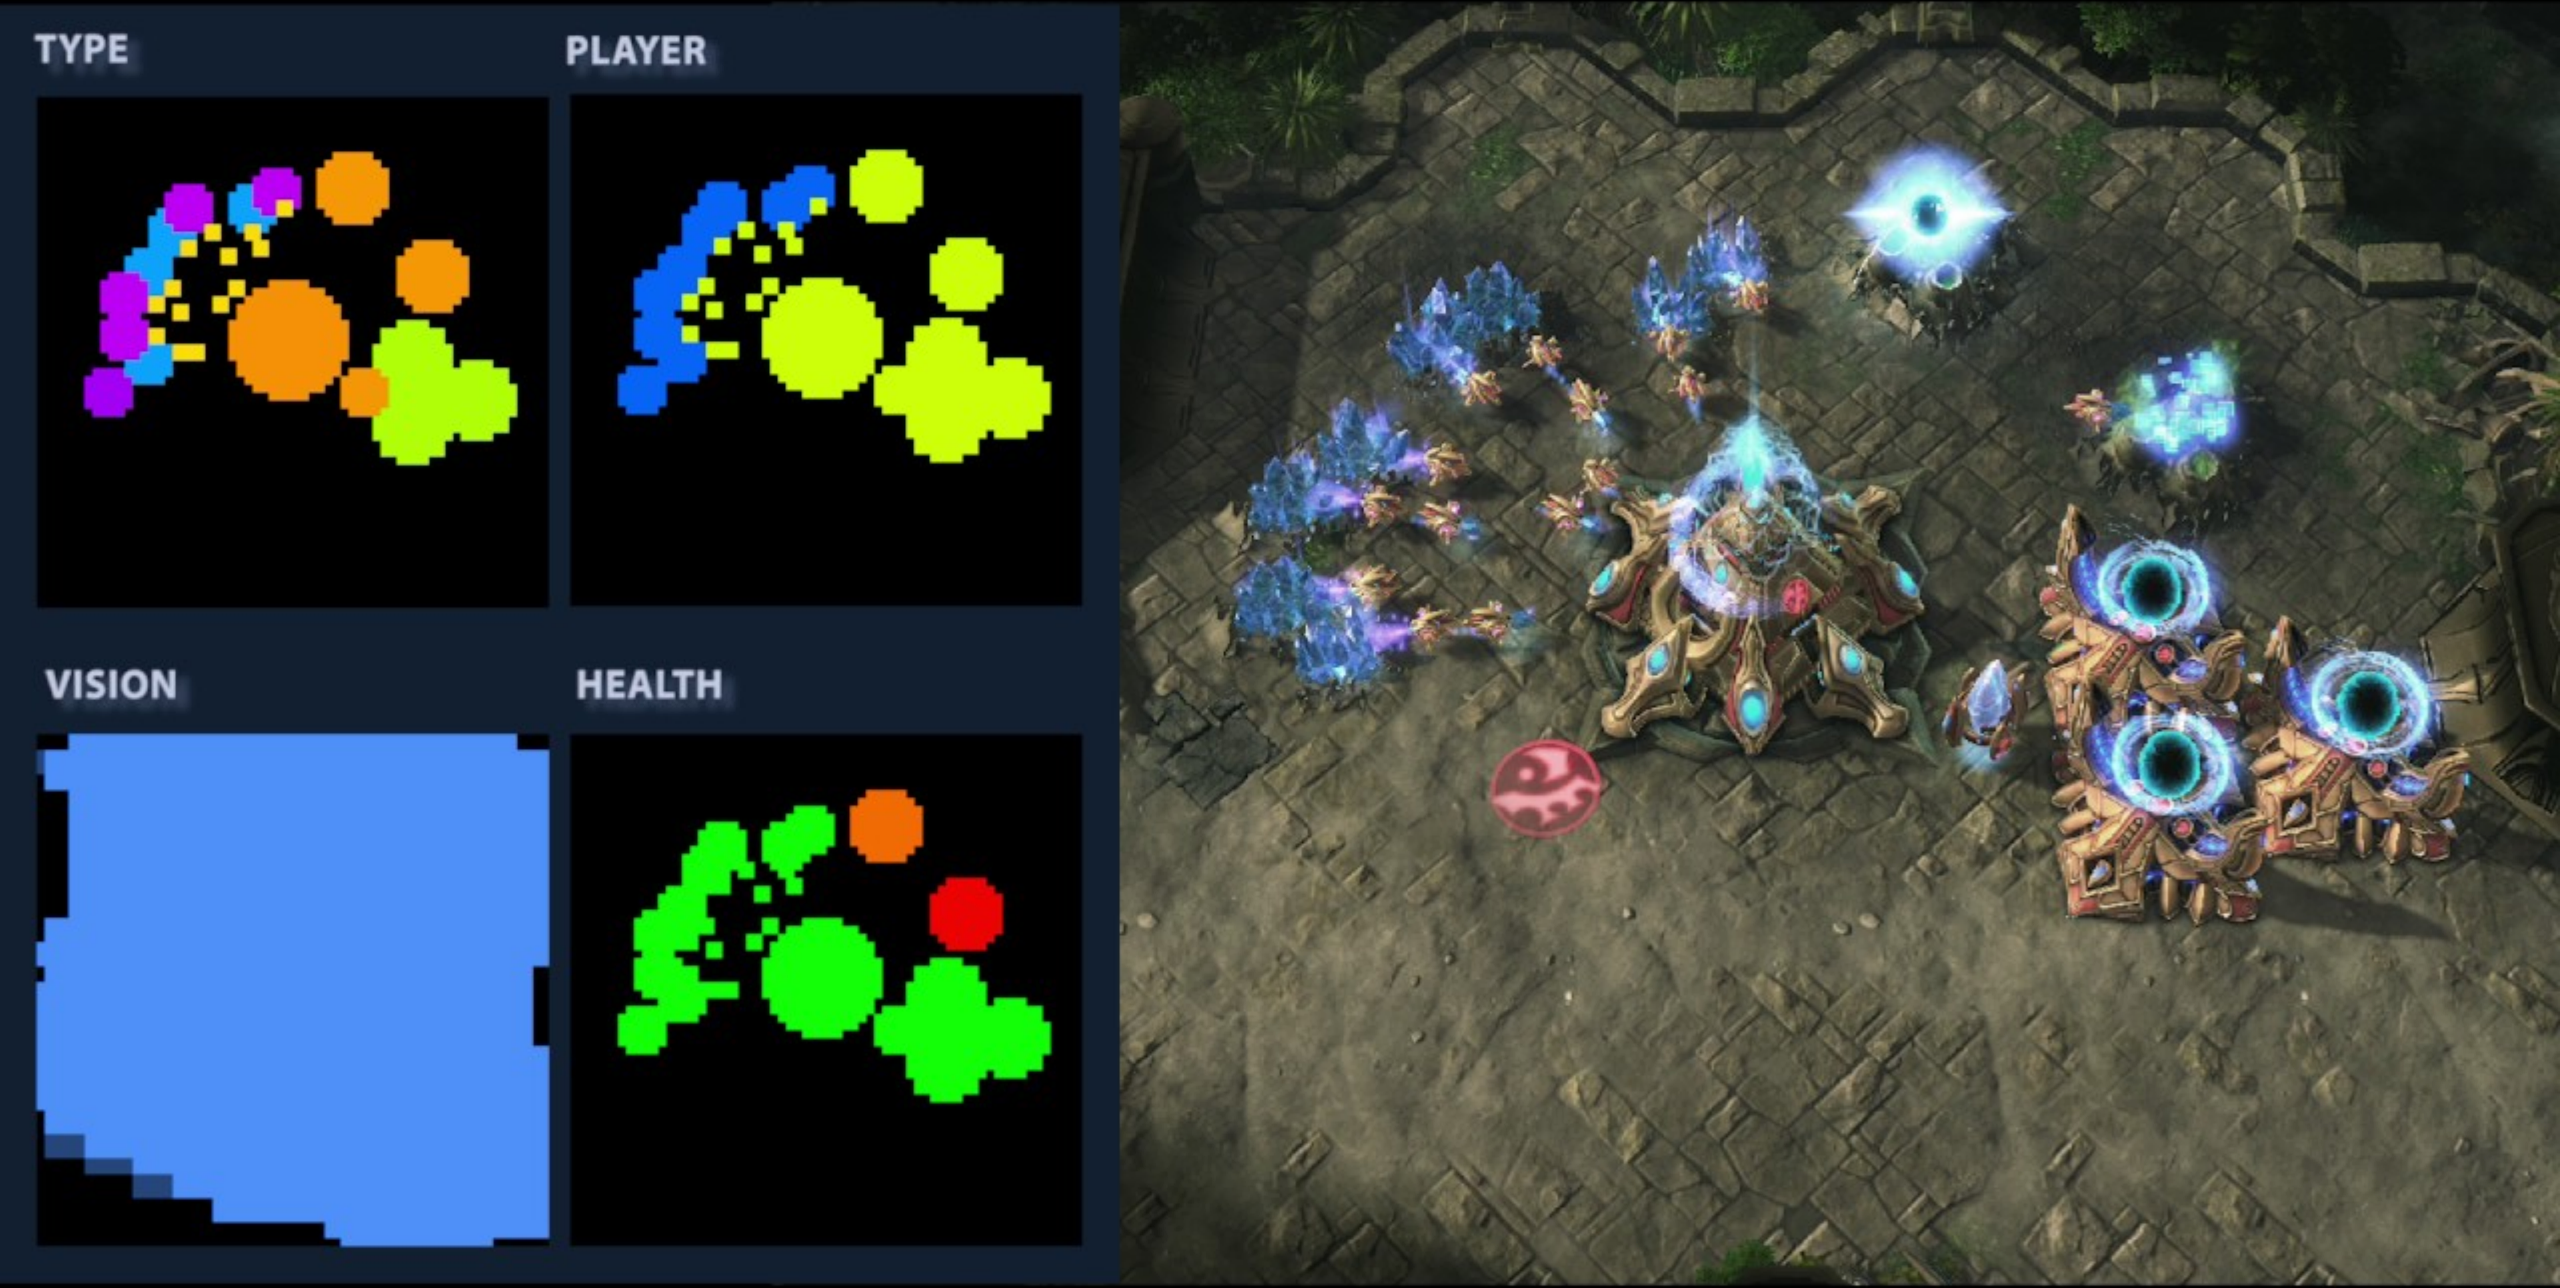
TYPE
PLAYER
VISION
HEALTH

POOL
POOL
POOL
RELU
RELU
RELU
RELU
RELU
RELU
CONV
CONV
CONV
CONV
CONV
CONV
FC
car
truck
airplane
ship
horse

主要内容

- 为什么神经网络流行起来?
- 神经网络原理?
- 有多少神经网络形式?
- 神经网络+强化学习?
- 神经网络的缺点?
- 我的研究

Mofan Zhou

为什么流行?

- 黑盒模型
- 复杂/简单的问题都能用
- 深度学习
- 数据已有一大堆
- 计算机硬件提升

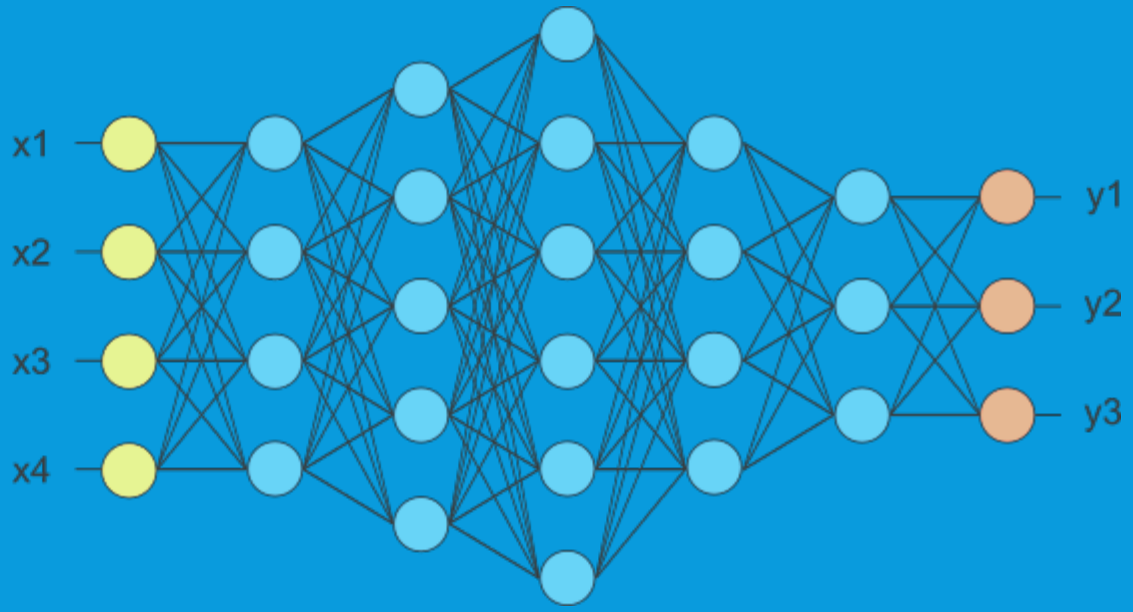

Mofan Zhou

为什么流行?

黑盒模型

模型: 将一种数据变成另一种数据.

$$x = vt + \frac{1}{2}at^2$$

比如用加速度和速度求得距离就可以看作一个模型.

x $vt + 1/2at^2$ t

结果 ← 模型 ← 数据

机器学习研究者常挂在嘴边的一句话: “神经网络是一个黑盒”.

为什么流行?

黑盒模型

加速度模型不是一个黑盒模型, 因为它有固定的物理公式.

$$x = vt + \frac{1}{2}at^2$$

黑盒模型没有固定的物理公式, 我们不知道里面发生了什么, 但正是因为没有复杂的物理公式, 从另一个角度看, 计算机处理的问题可能变复杂了, 但是人处理的问题反而更简单了.

为什么流行?

复杂/简单的问题都能用

大到读懂图片, 小到寻找数据间的简单关系, 神经网络都能胜任.

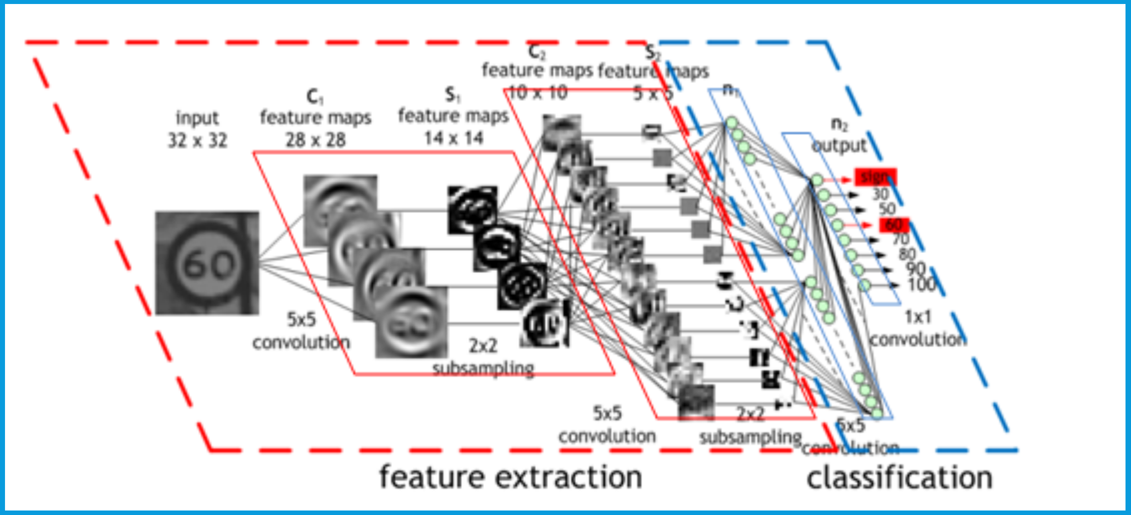

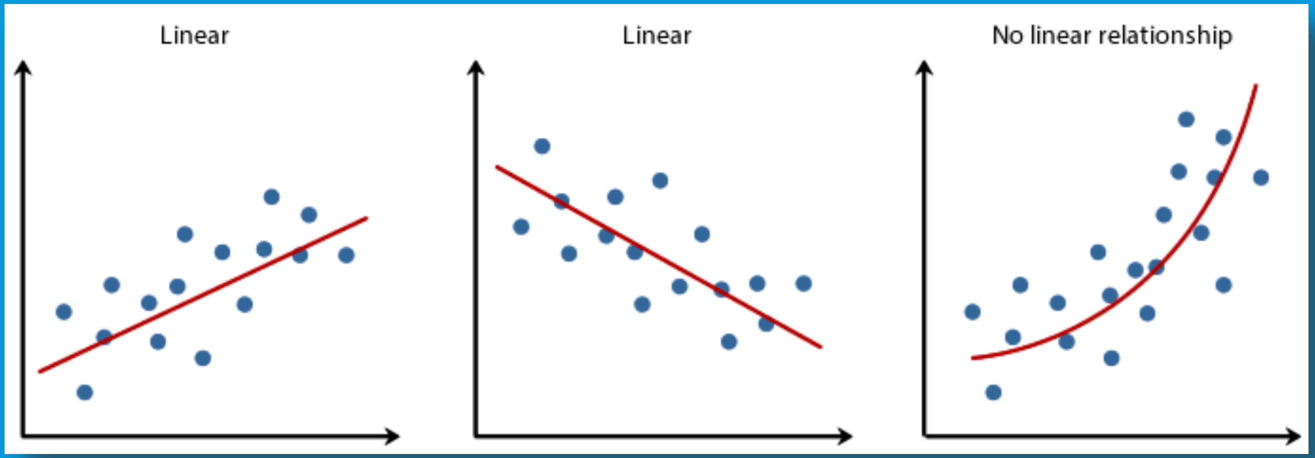

为什么流行?

深度学习

最开始的神经网络局限性很多, 大多都是简单的浅层神经网络. 当加深神经网络层数, 无可避免的问题 (比如梯度消失) 将会产生, 而且并没有非线性化元素 (不能处理复杂问题).

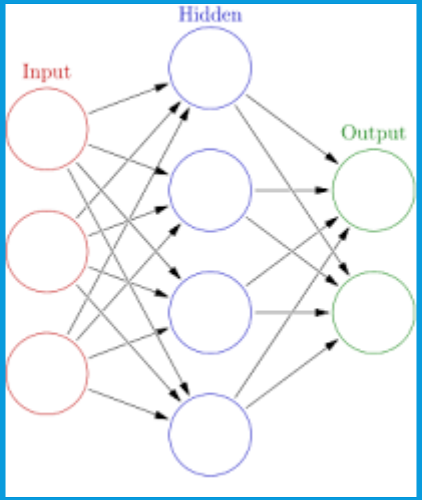

如今深度学习 (将神经网络加深) 已不再是问题, 非线性化元素 (激活函数) 的加入, 让神经网络引领了整个深度学习.

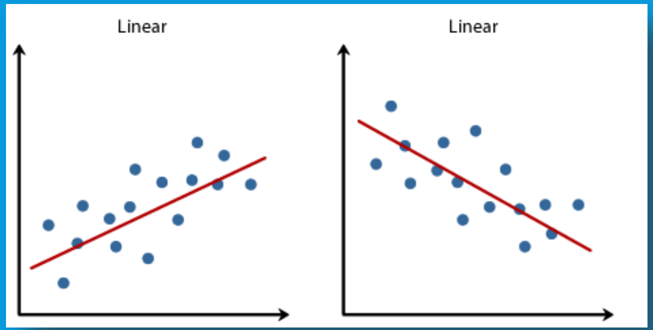

为什么流行?

数据已有一大堆

- 神经网络使用数据训练
- 数据越来越多
- 一般, 数据越多, 预测越准

MNIST
6万张训练
1万张测试

VGG Face
200+万张训练
2622人

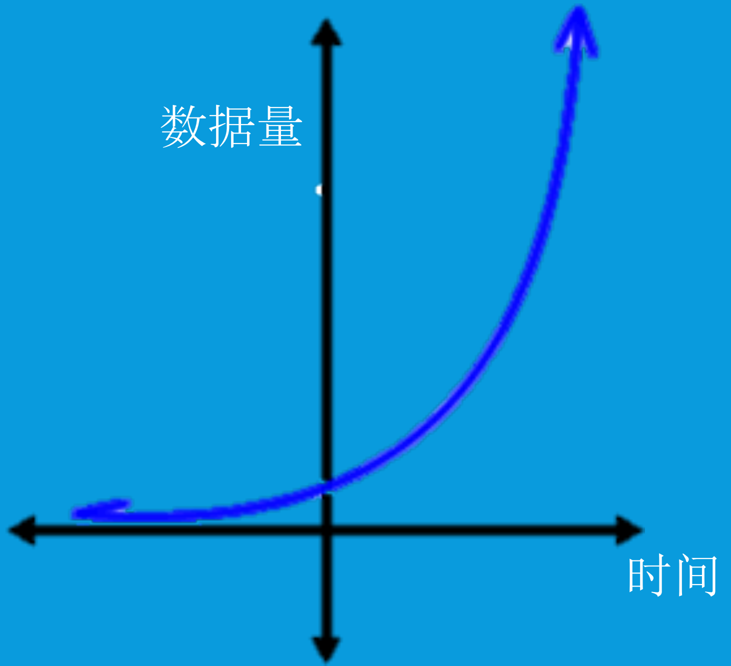

Mofan Zhou

为什么流行?

计算机硬件提升

多核计算机

- 核少,但强大
- 并行运算
- 同步更新
- 加速训练

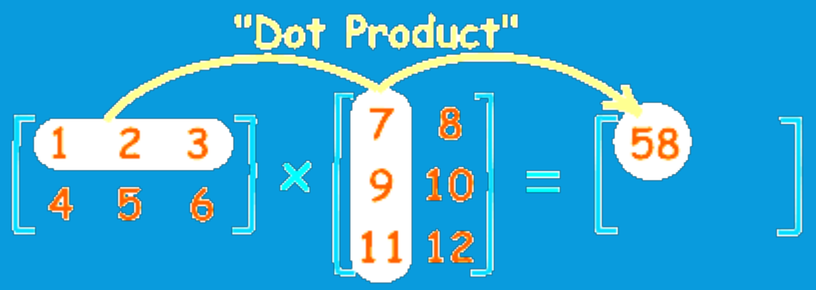

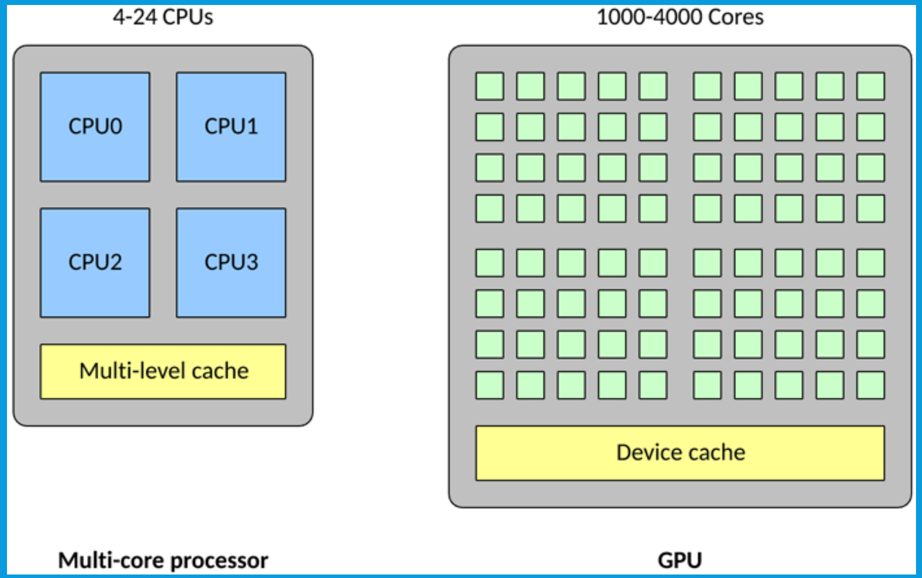

GPU支持

- 核不强大,但多
- 高度并行
- 矩阵计算优化

原理?

- 数学优化问题 (Optimization)
- 梯度下降 (Gradient Descent)
- 反向传播 (Back-propagation)

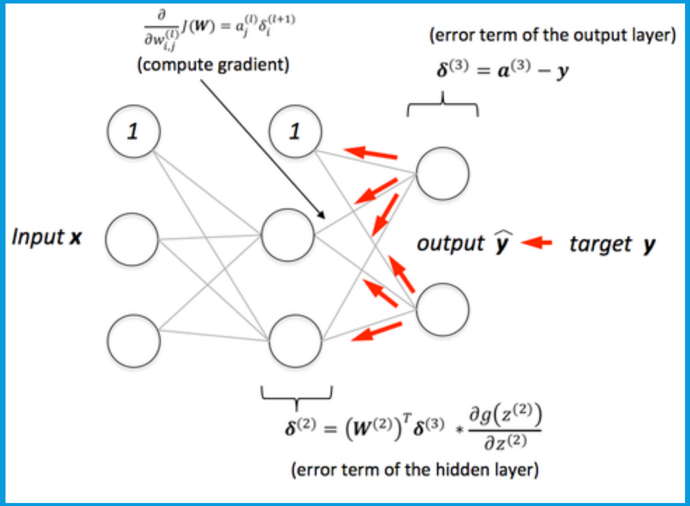

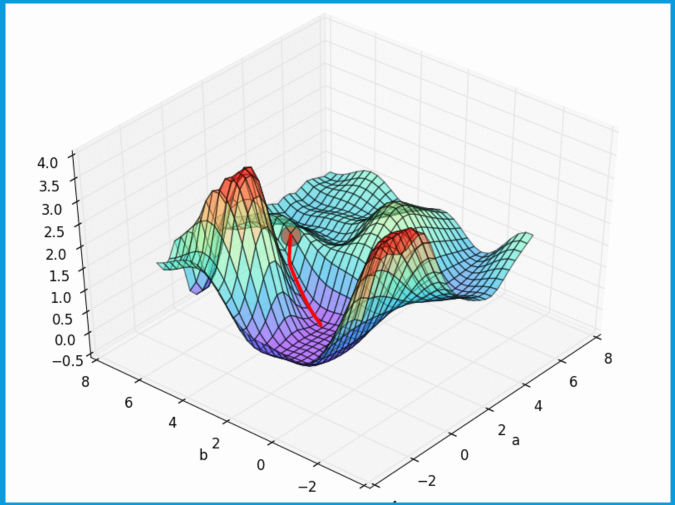

Mofan Zhou

原理?

数学优化问题 (Optimization)

自从有了数学, 优化就是人类的好工具. 生活中的优化问题处处可见, 比如做生意最大化收益, 最小化损失, 做物流最短化运送路线等等.

一般的优化问题是一个 最大化/最小化 问题. 解决了优化问题, 就是找到了最大点/最小点.

优化问题不止一种方法, 目前流行的神经网络用的是梯度下降法 (gradient descent).

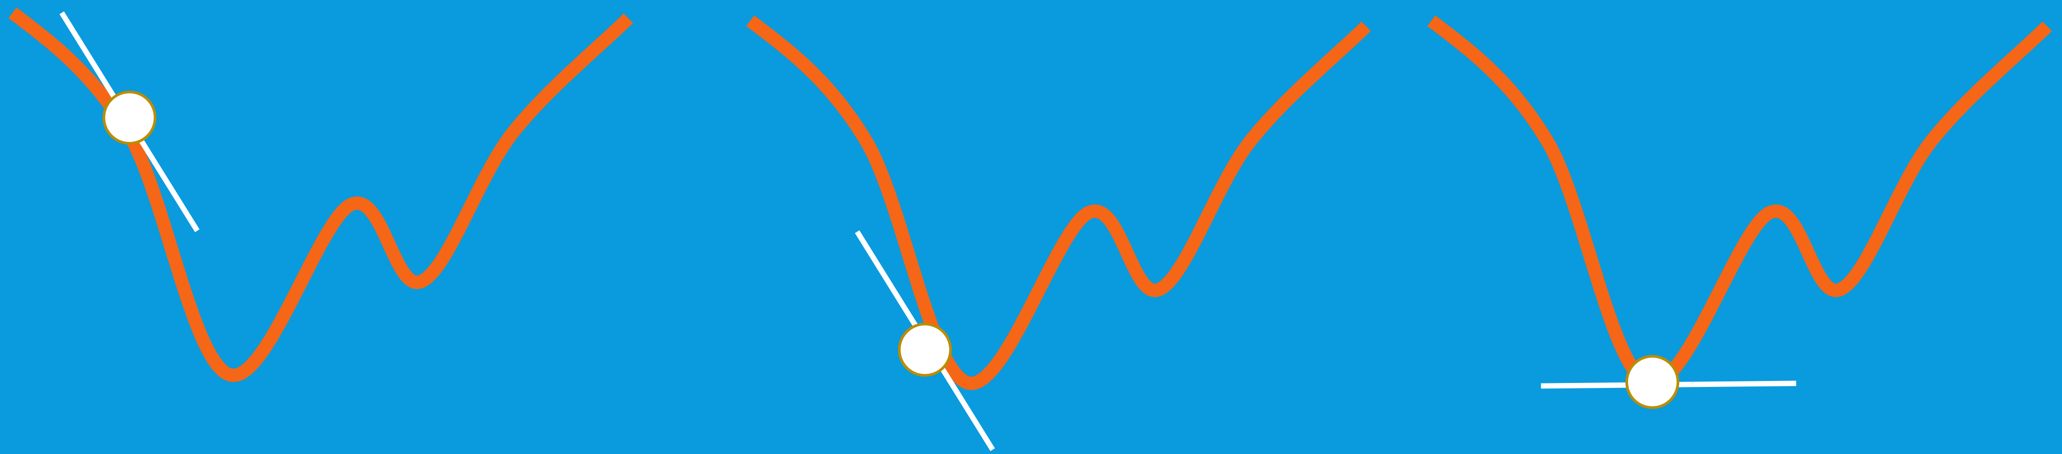

Mofan Zhou

原理?

梯度下降 (Gradient Descent)

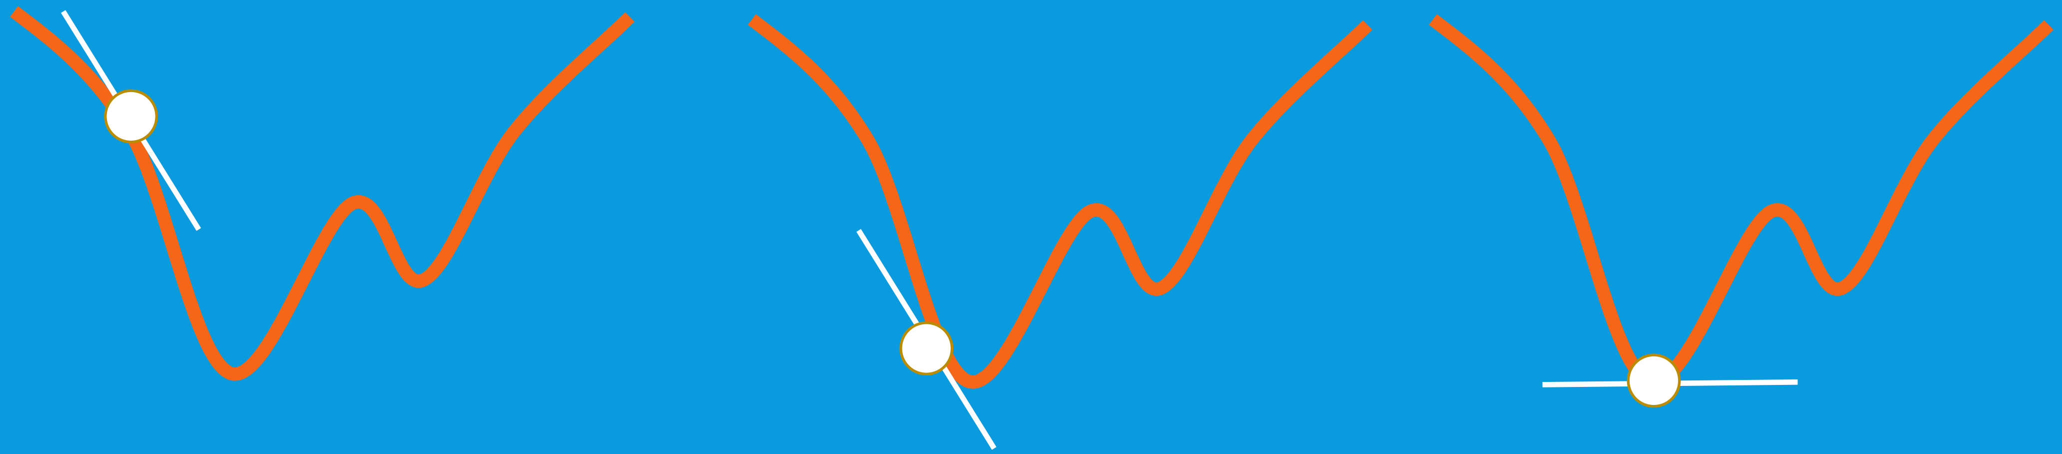

使用梯度和迭代, 一次次慢慢接近最小点, 白色的梯度线指明了要下降的方向.
梯度线不断变化, 当它躺平后, 迭代结束, 任务完成, 找到了某一个最小点.

原理?

梯度下降 (Gradient Descent)

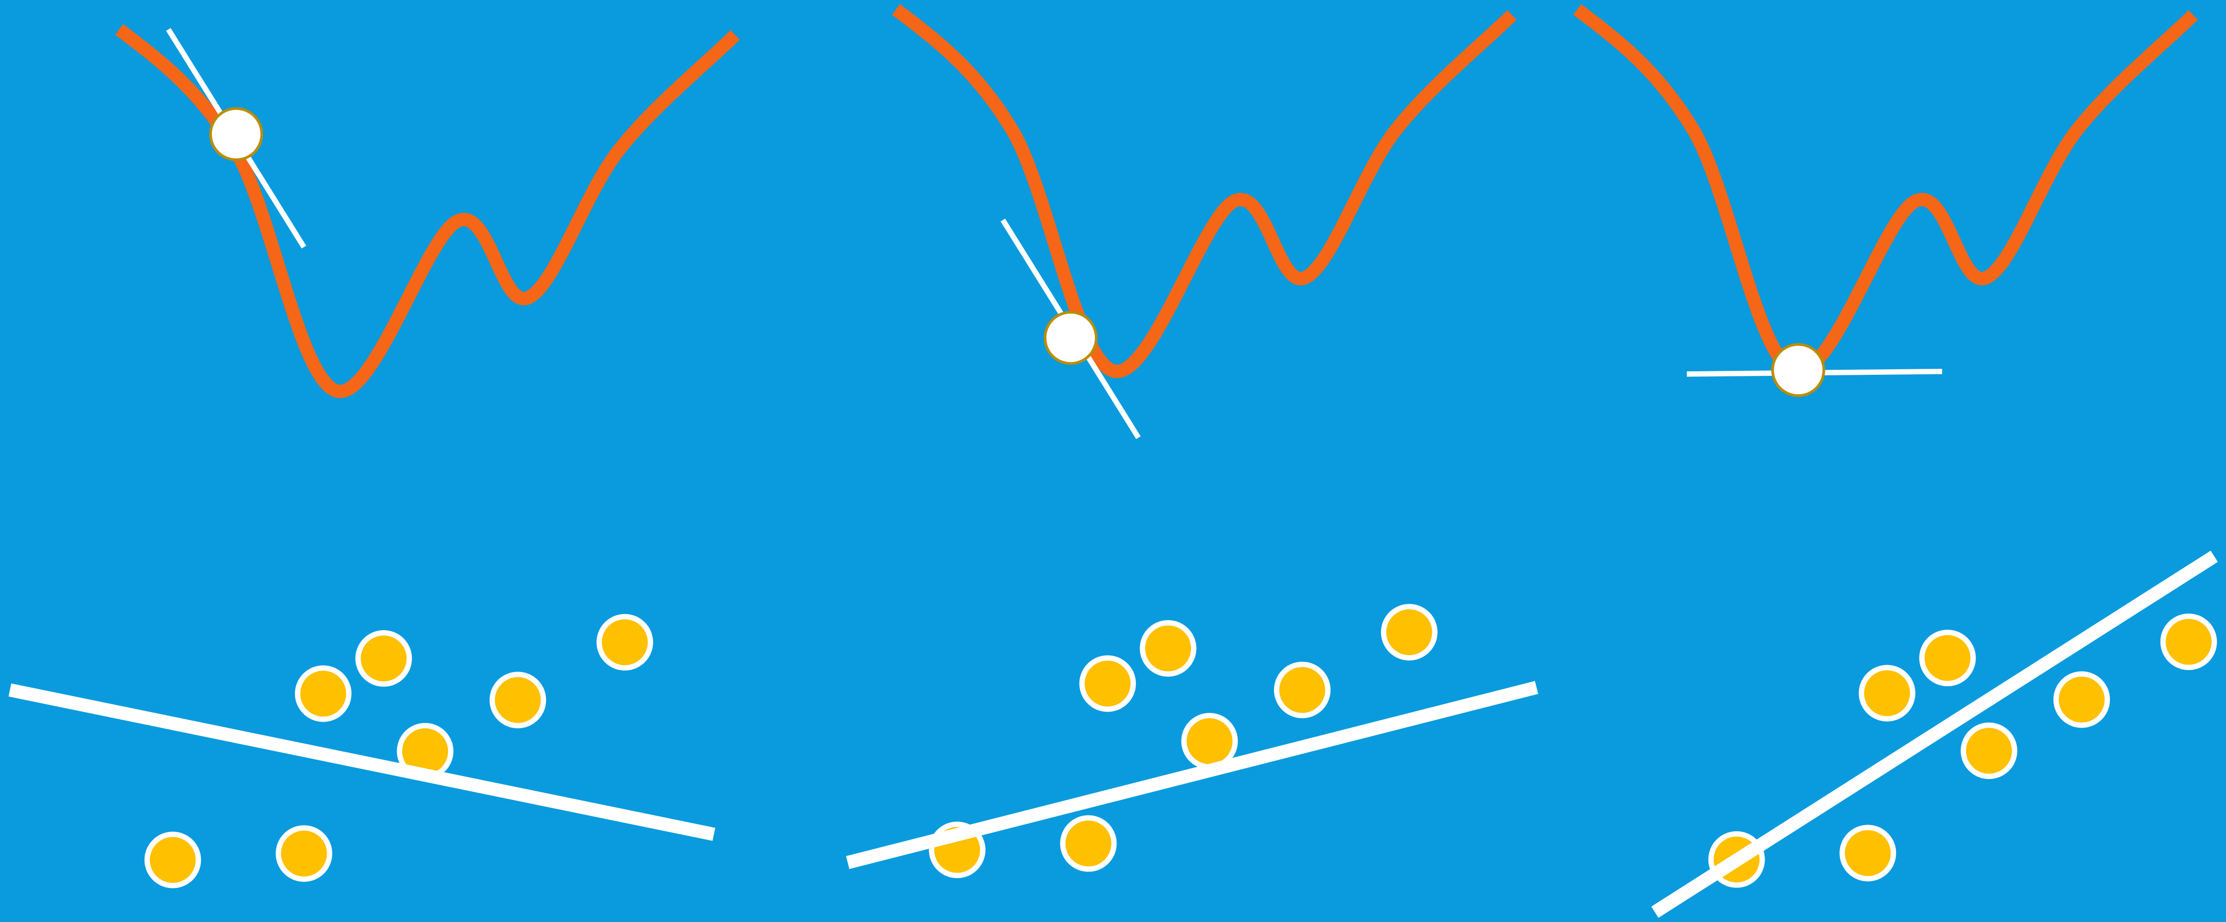

Mofan Zhou

原理?

梯度下降 (Gradient Descent)

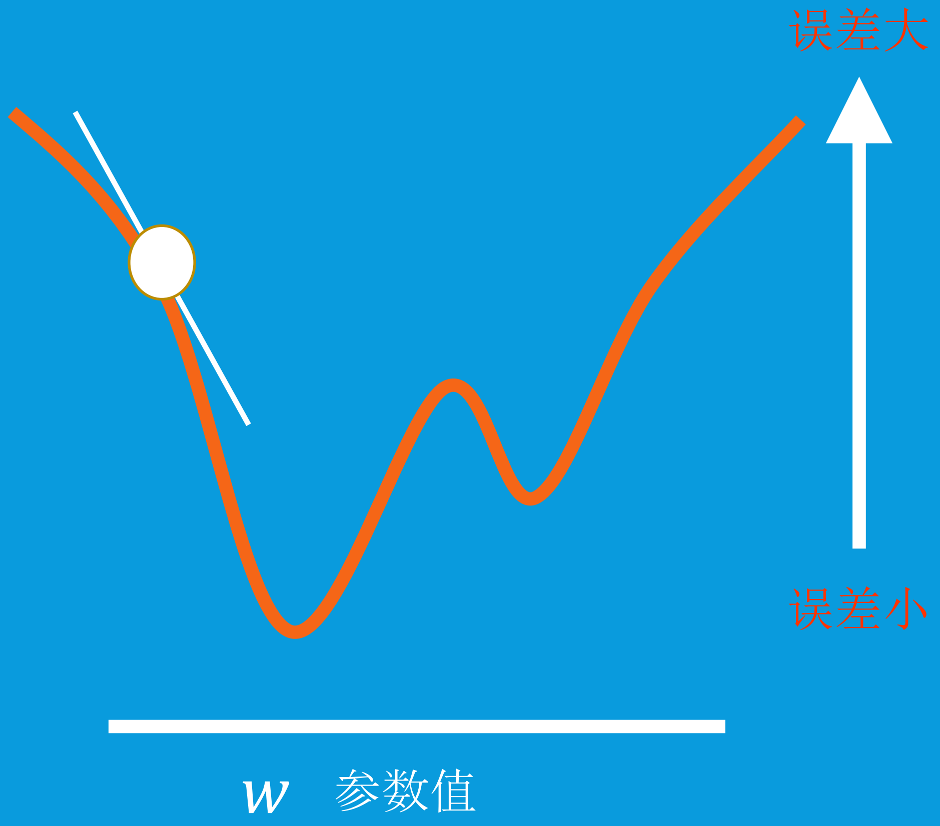

红线是一条误差曲线, 当 w 参数到达不同的数值, y方程和数据之间的误差将会不同.

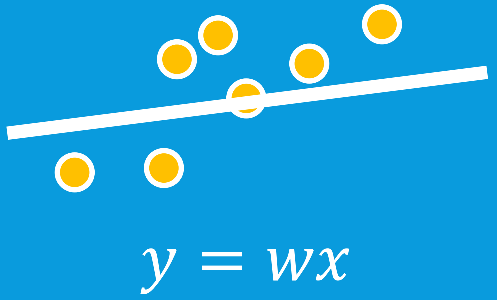

通过不断调整 w 参数的值, 使得 y 方程和真实数据点的误差最小. 而调整 w 参数的方法使用到了梯度, 所以这就叫梯度下降法.

原理?

反向传播 (Back-propagation)

神经网络运用了梯度下降. 每一个神经联结中都有一个 w 这样的参数, 每一个 w 参数都能用梯度下降法慢慢调整. 使得最后计算得出的 y 和真实数据越来越接近.

神经网络的优化顺序:

1. 接收 x 数据
2. 逐层计算和传播 x 数据
3. 对比计算得到的 y 和 真实数据的差别
4. 反向传递误差/(梯度下降)更新参数

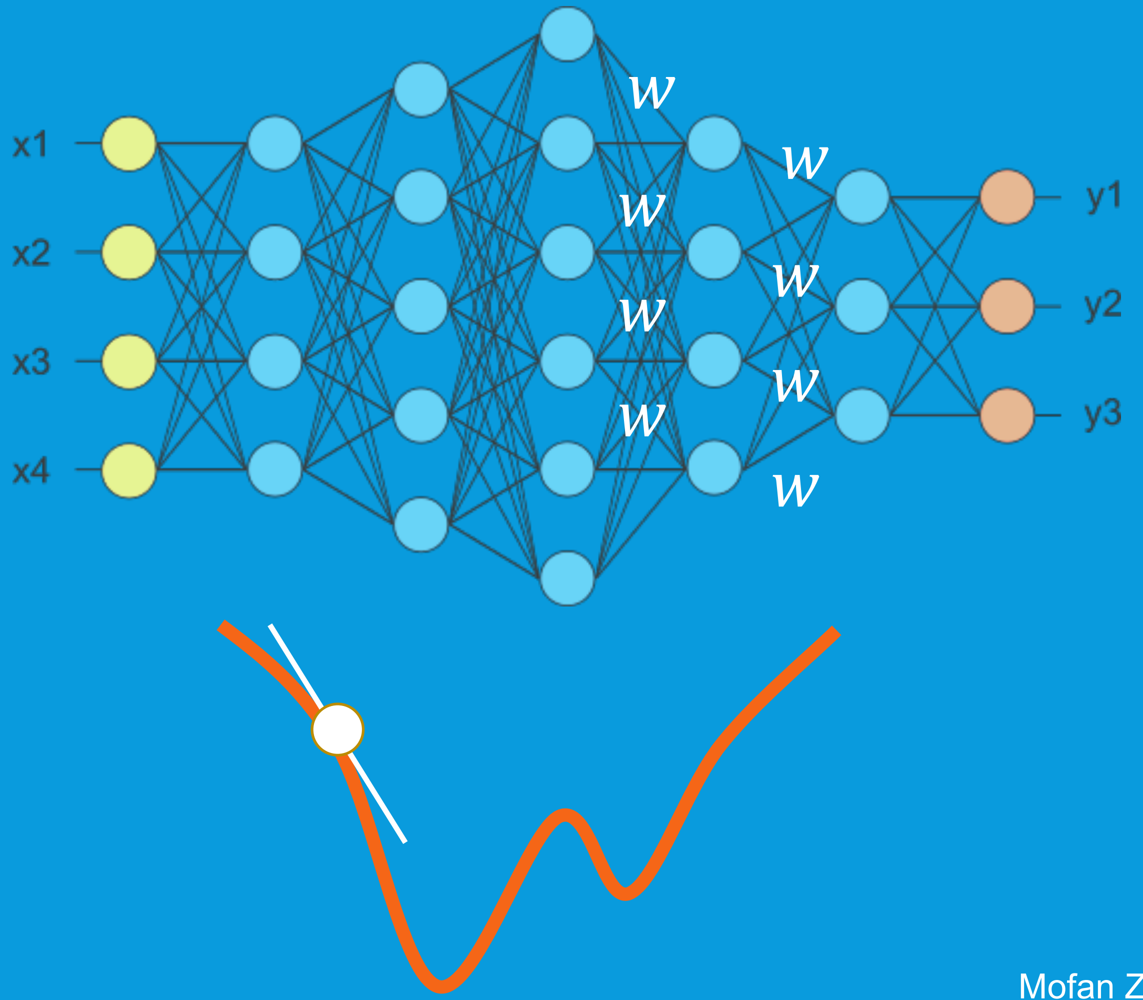

Mofan Zhou

网络形式?

- 全连接 (fully connected)
- 图像 (CNN)
- 语音/序列 (RNN)
- 生成器 (GAN)
- …. (AutoEncoder)

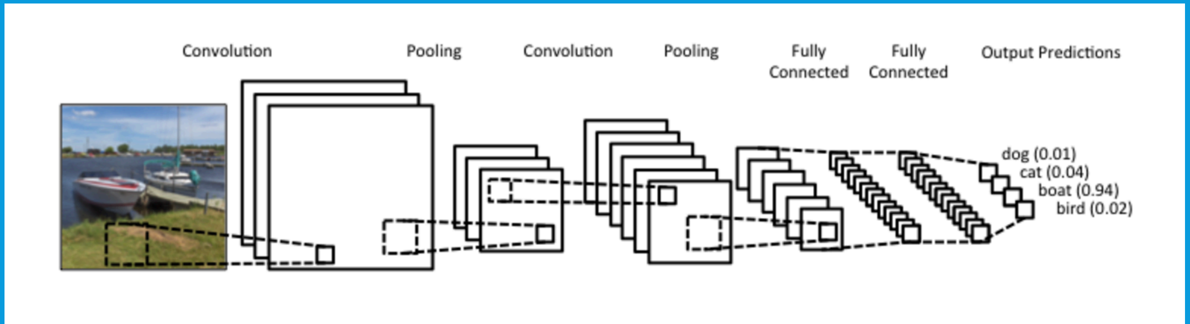

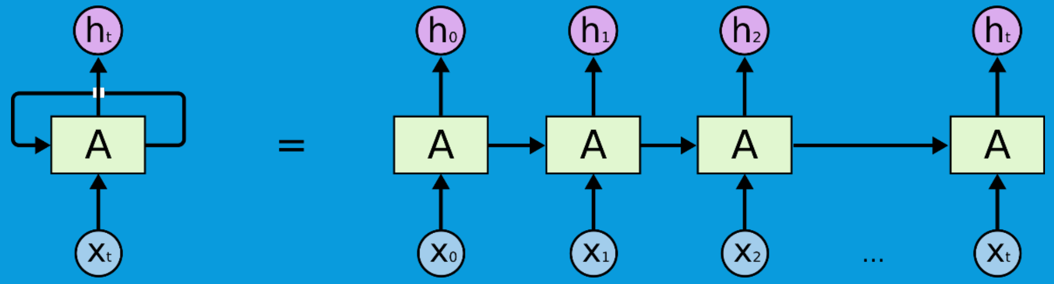

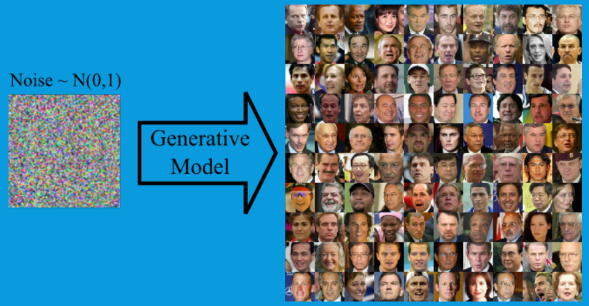

Mofan Zhou

网络形式?

全连接 (fully connected)

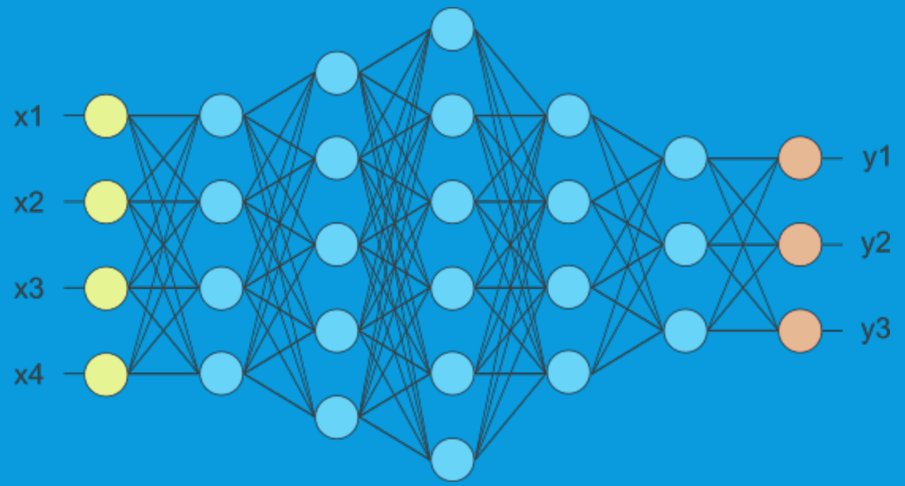

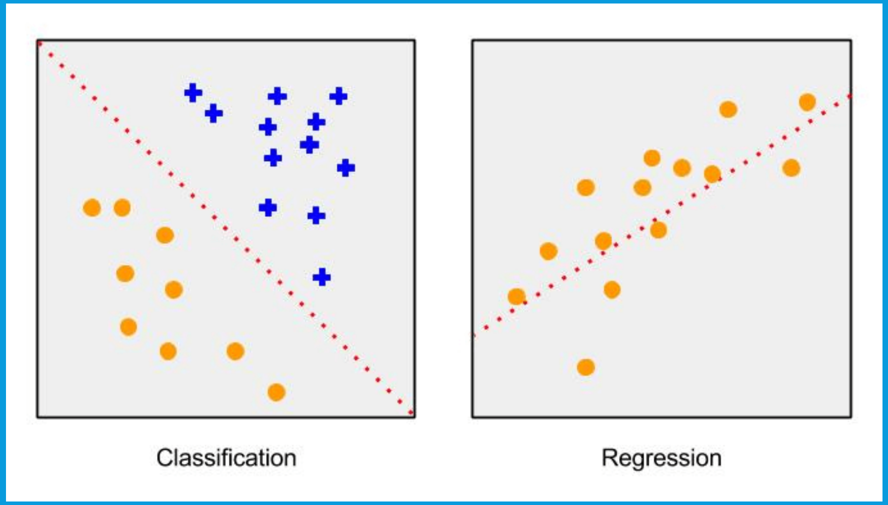

- 最基本形式
- 简单实用
- 适用于大多数问题
- 预测值 (regression) (房价, 电费, 股票)
- 分类 (classification) (人脸识别, 垃圾邮件)

网络形式?

图像 (CNN)

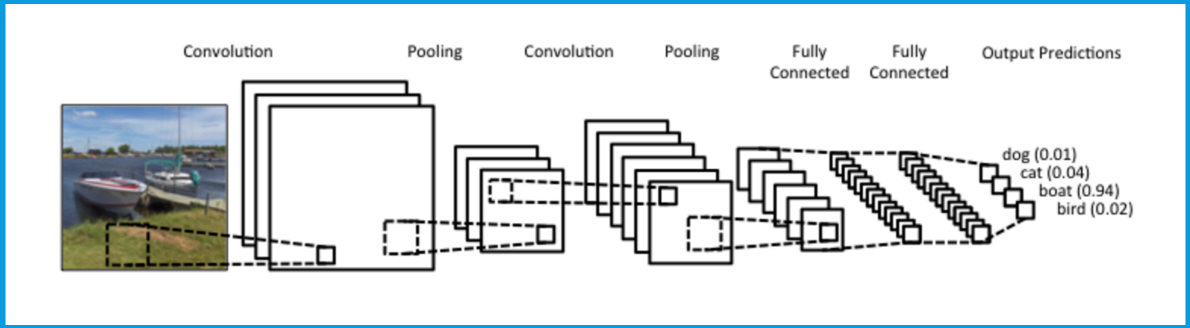

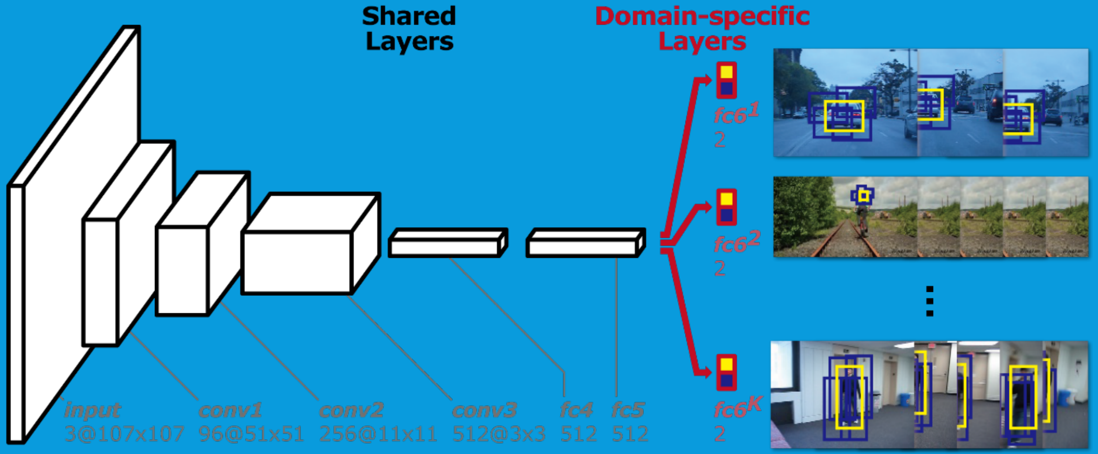

- Convolutional Neural Networks 卷积神经网络
- 读懂图像
- 卷积
- 采样获取图片中的重要信息
- 重复卷积/采样的步骤
- 获得图片中的关键信息
- GPU

网络形式?

图像 (CNN)

工作原理

- 卷积
  - 过滤器 (滤波器 filter)
  - 增加理解度 (厚度)
- 采样 (池化)
  - 提取重要信息
  - 减少计算负担
- 全连接层
  - 输出判断

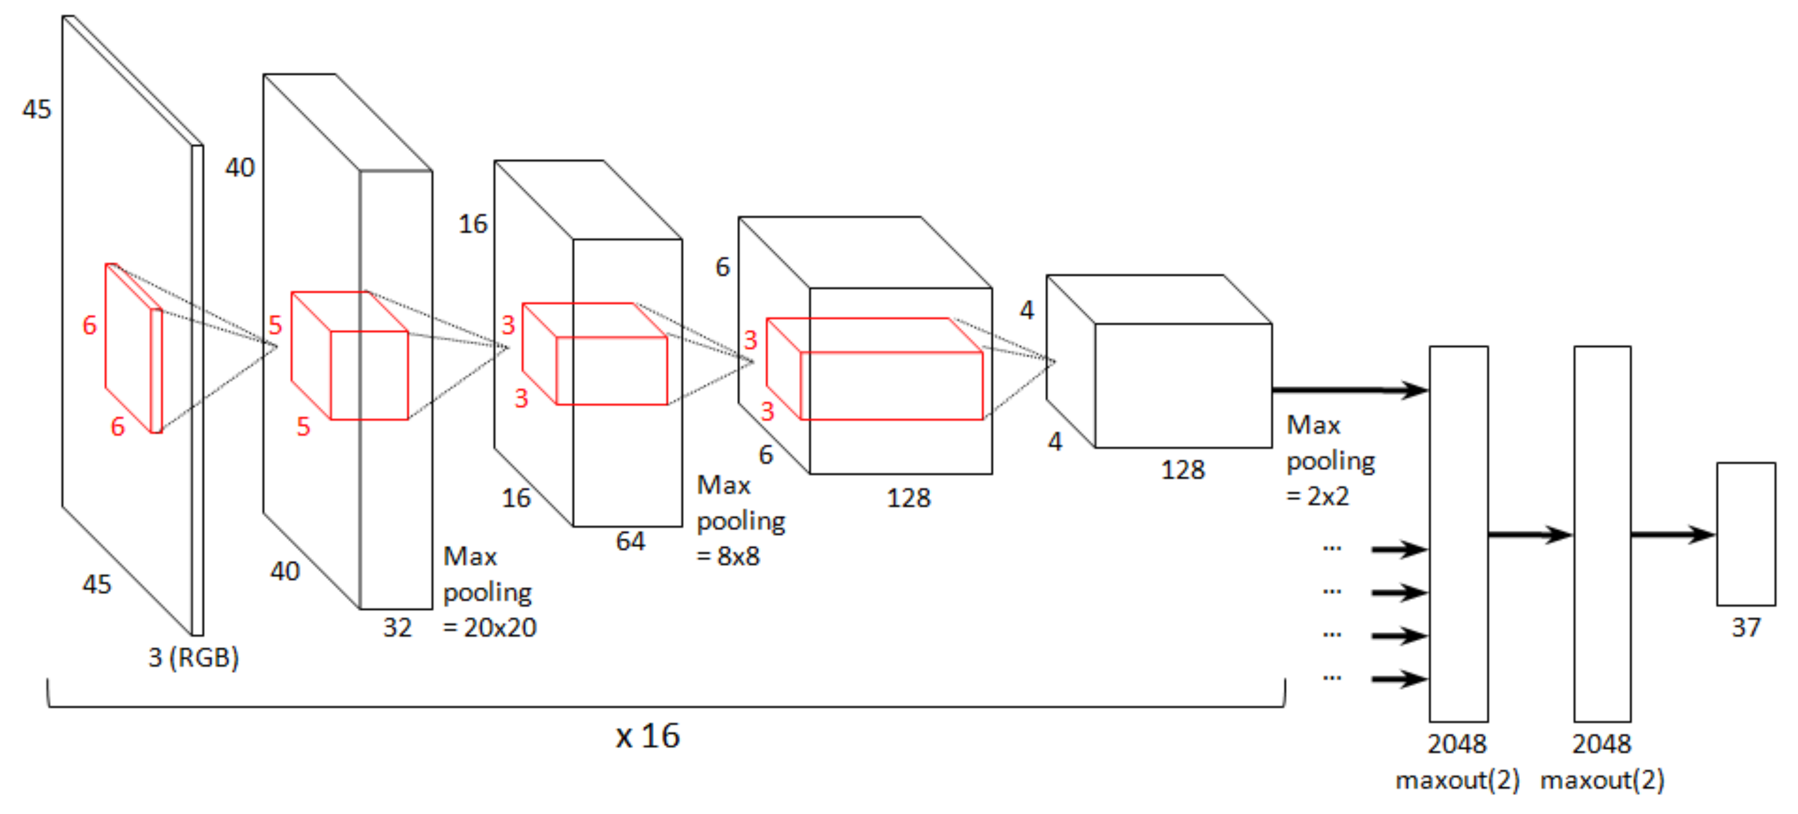

网络形式?

图像 (CNN)

LeNet

(LeCun et al., 1998)

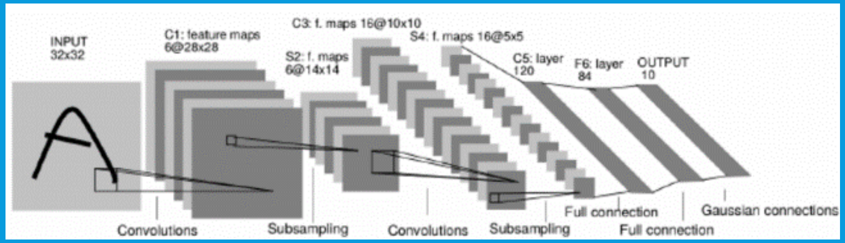

VGG Net (Simonyan & Zisserman, 2014)

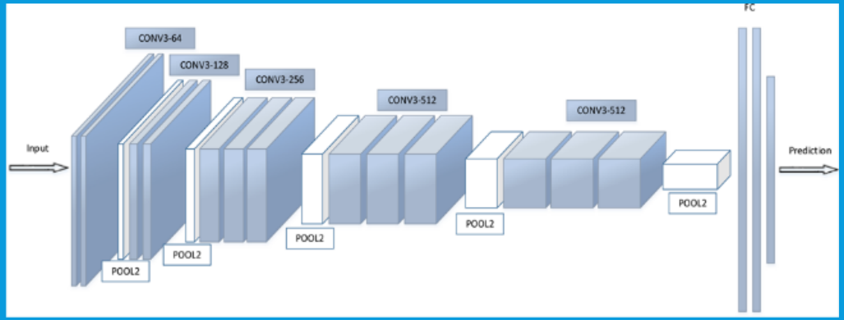

GoogLeNet (Szegedy et al., 2015)

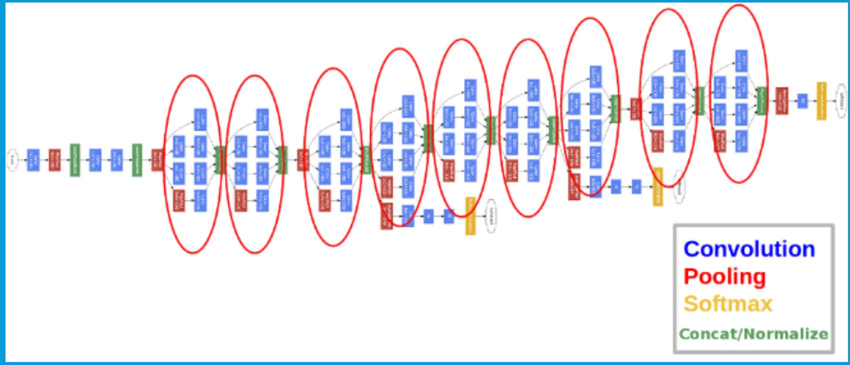

ResNet

(Szegedy et al., 2015)

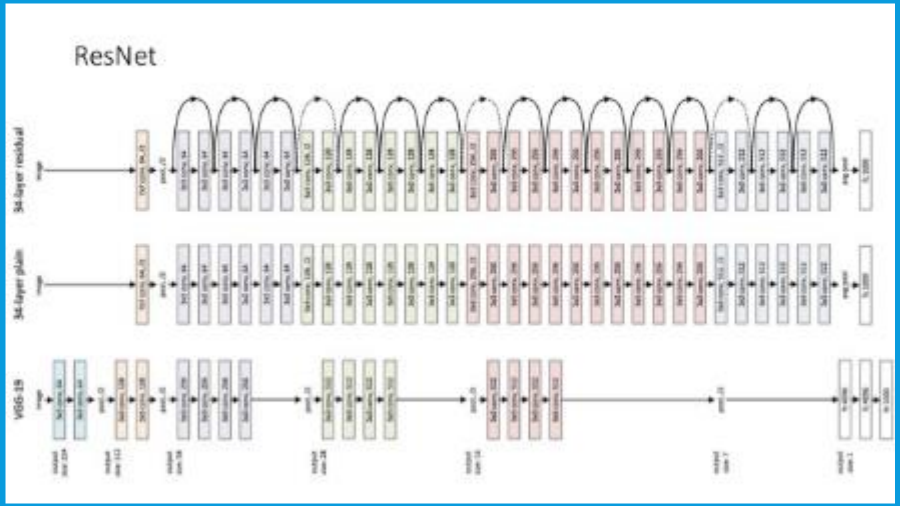

R-CNN

Fast R-CNN

Faster R-CNN

(Girshick … 2013-2015)

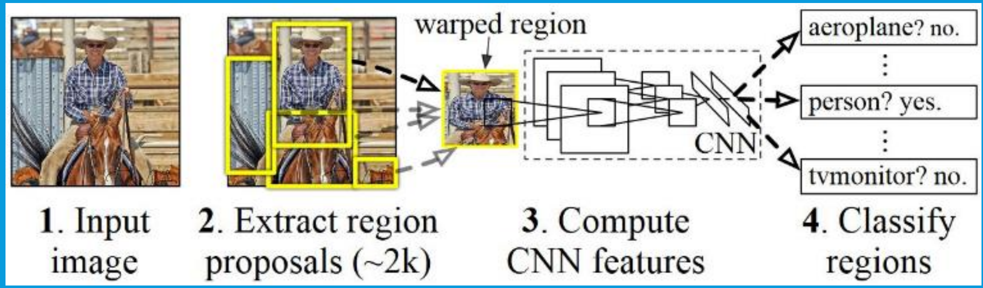

来源

网络形式?

语音/序列 (RNN)

- Recurrent Neural Networks 循环神经网络
- 运用在序列化数据
- 上一段数据影响下一个预测
- 顺序是关键
  - "今天比昨天冷" vs "昨天比今天冷"
  - 试试你能不能倒过来念你的手机号码
- 神经网络有"记忆"
- 记忆中的状况+现在的状况

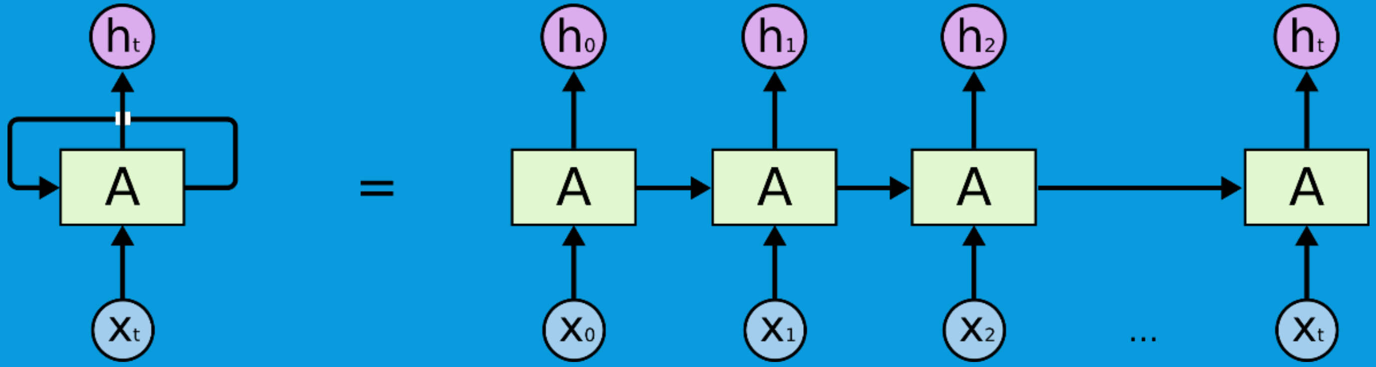

网络形式?

语音/序列 (RNN)

普通的神经网络

- 不分先后
- 现在的预测只和现在的数据有关

循环神经网络

- 分先后
- 现在的预测不仅仅和现在的数据有关，和对前面数据的理解也有关 (记忆)

声音来源

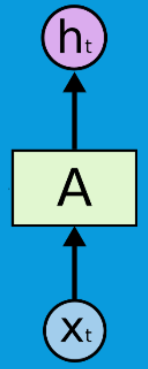

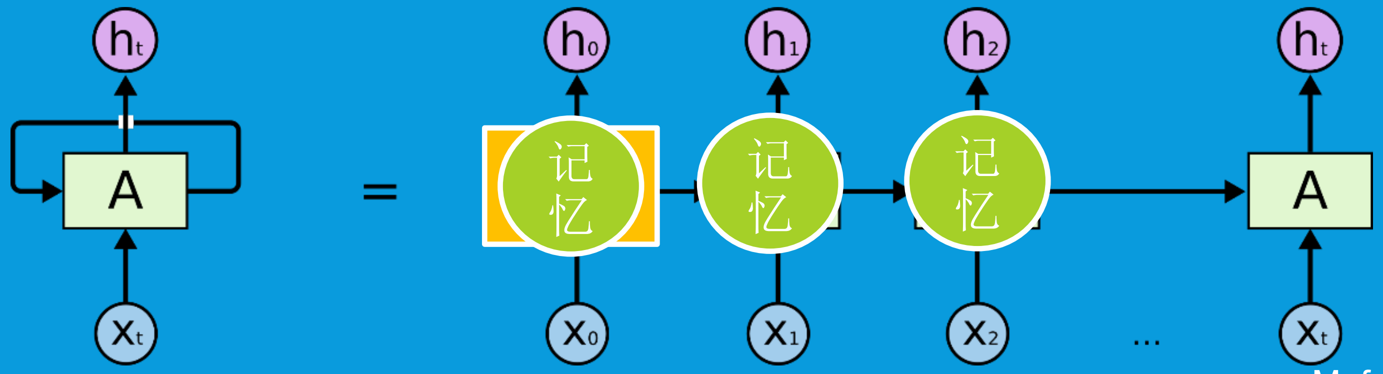

Mofan Zhou

网络形式?

语音/序列 (RNN)

RNN 有个 ”健忘” 的问题 (梯度弥散/消失 gradient vanishing), 为了解决这个问题, Long-Short Term Memory (LSTM) (Hochreiter, 1997) 被提出, 在梯度下降方面给出了一个高速通道. 因为 LSTM 的结构比普通 RNN 要复杂, 所以为了简化这个形态, 后续还有 LSTM 的简化版 Gated Recurrent Unit (GRU) 在 2014 被提出 (Cho et al., 2014).

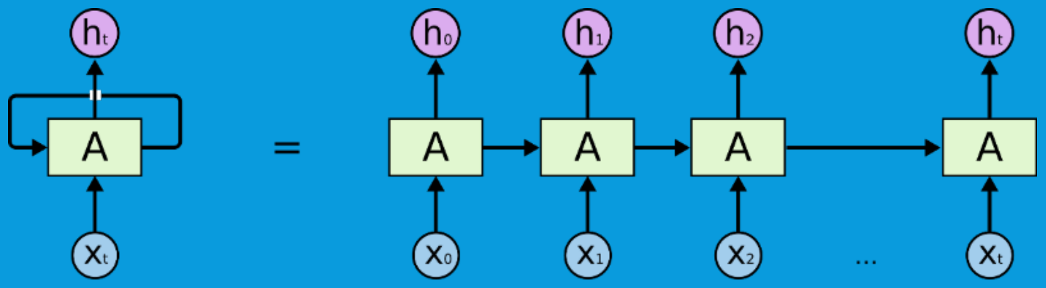

RNN

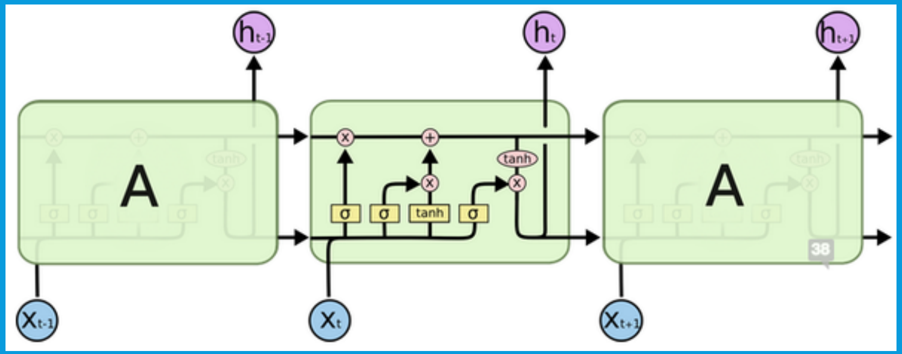

LSTM

Mofan Zhou

网络形式?

生成器 (GAN)

- Generative Adversarial Nets (Goodfellow et al., 2014) 生成对抗网络
- 生成/创造东西
- 创新式学习方式
- 生成器 (Generator), 判别器 (Discriminator)

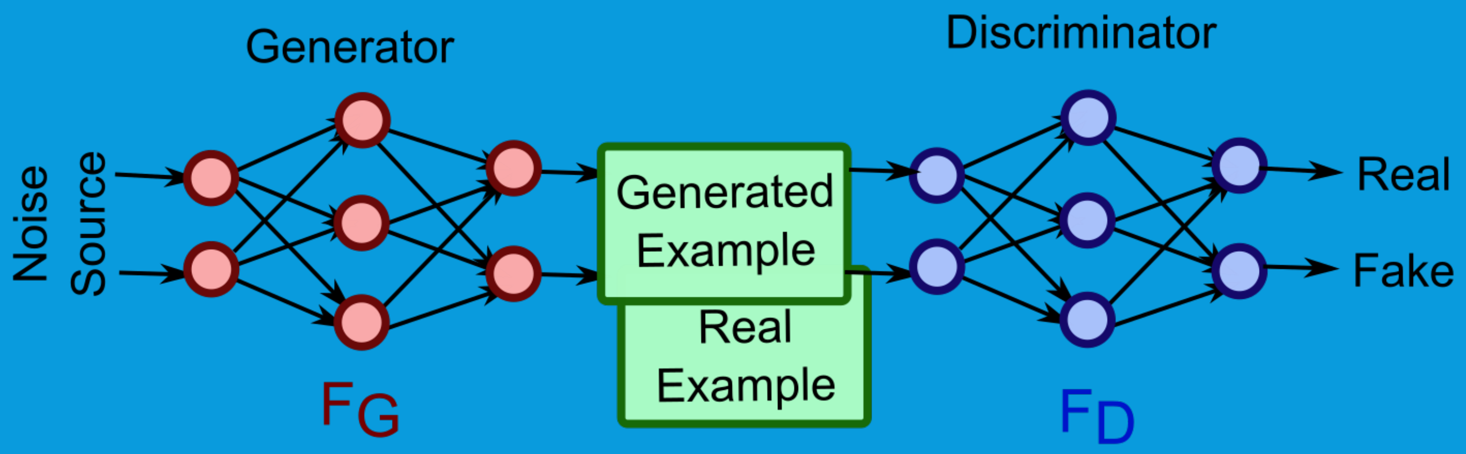

网络形式?

生成器 (GAN)

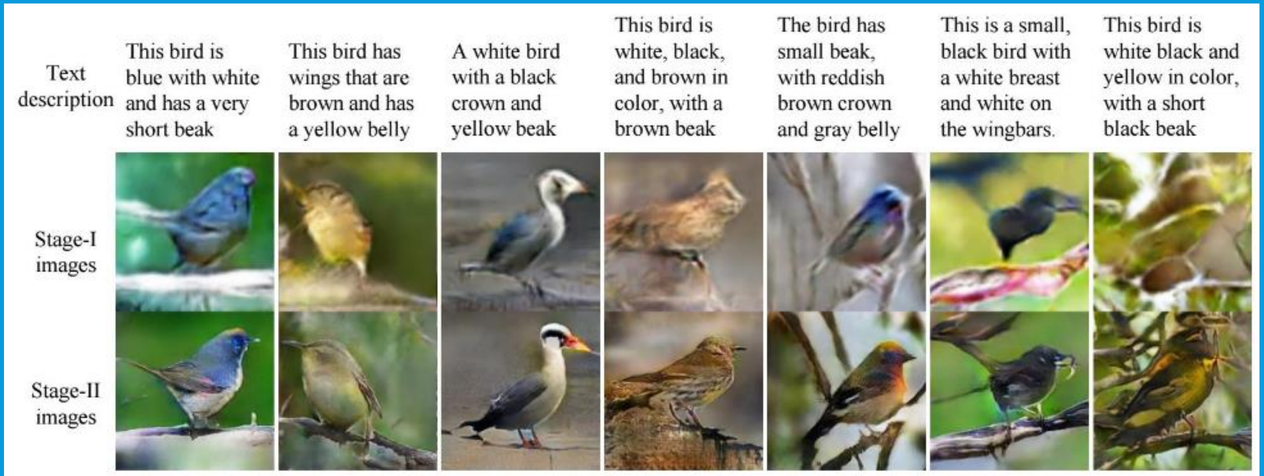

Zhang et al., 2016

Fig. 8. Applying our method to legacy black and white photos. Left to right: photo by David Fleay of a Thylacine, now extinct, 1936; photo by Ansel Adams of Yosemite; amateur family photo from 1956; *Migrant Mother* by Dorothea Lange, 1936.

Zhang et al., 2016

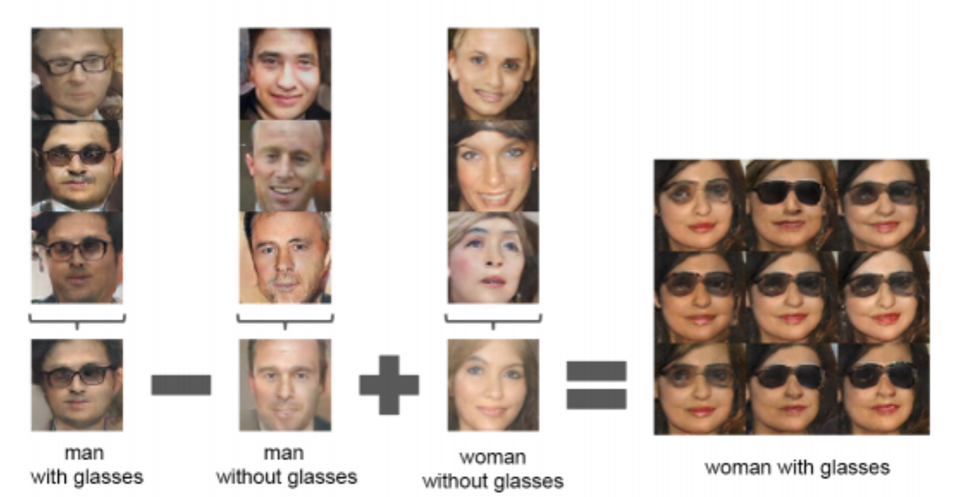

Radford et al., 2015

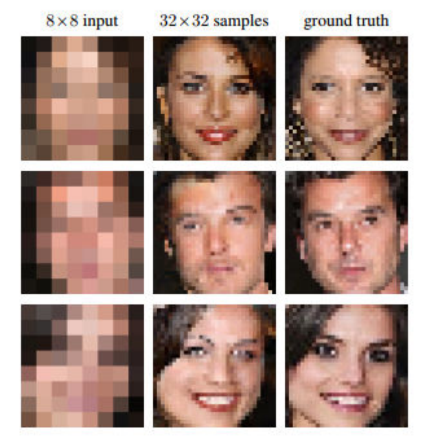

yan et al., 2017

Mofan Zhou

网络形式?

生成器 (GAN)

工作原理

- 生成器 (Generator) 生成结果
- 判别器 (Discriminator) 判断哪些是真是结果, 哪些是生成器生成出来的结果
- 判别器学习时顺便带着生成器一起学习

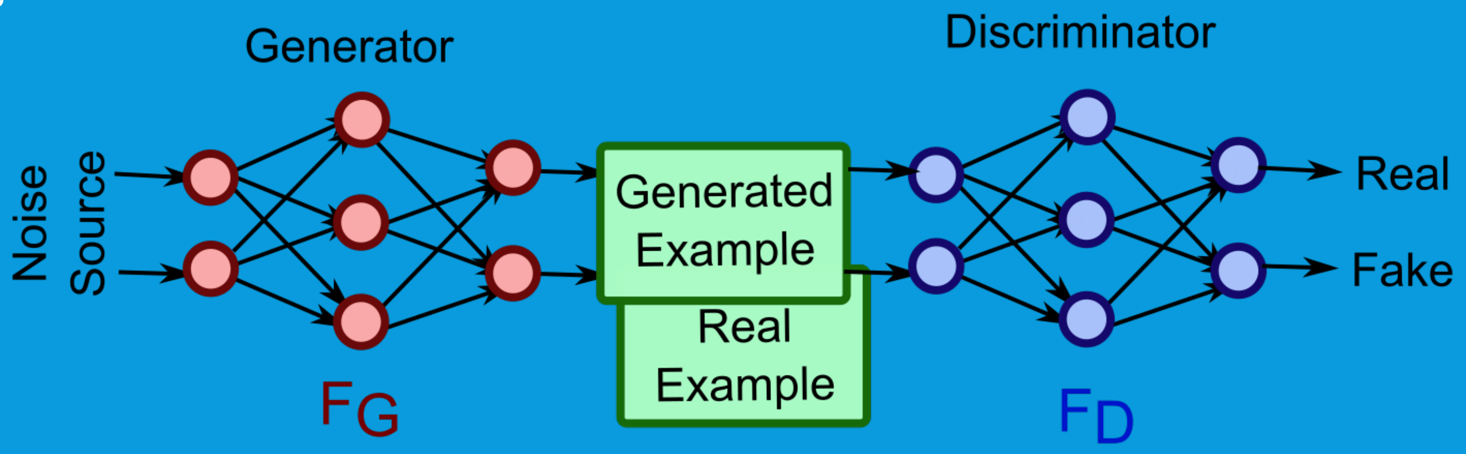

例子:

新手画家 (生成器) 学画画,

新手鉴赏家 (判别器) 学鉴赏,

鉴赏家要区分著名画作和新手画作,

并告诉新手画家怎么样变成著名画家,

新手画家越画越像著名画家.

神经网络+强化学习?

- Reinforcement Learning
- 在环境中求生存的游戏
- 在互动中学习, 没有学习样本 (监督学习)
- 没有老师
- 只有环境, 机器人, 奖惩

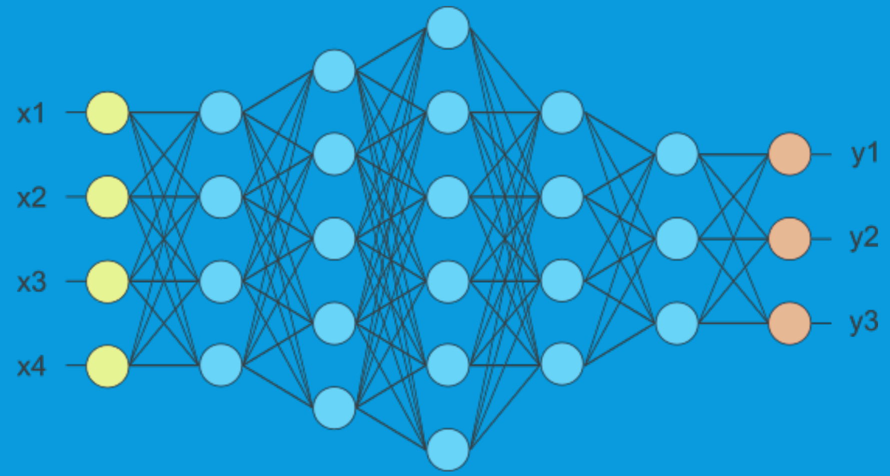

传统的强化学习是没有神经网络结构的,但是因为神经网络的优越性 (高度非线性化, 参数复杂化). 人们渐渐将神经网络和强化学习结合.

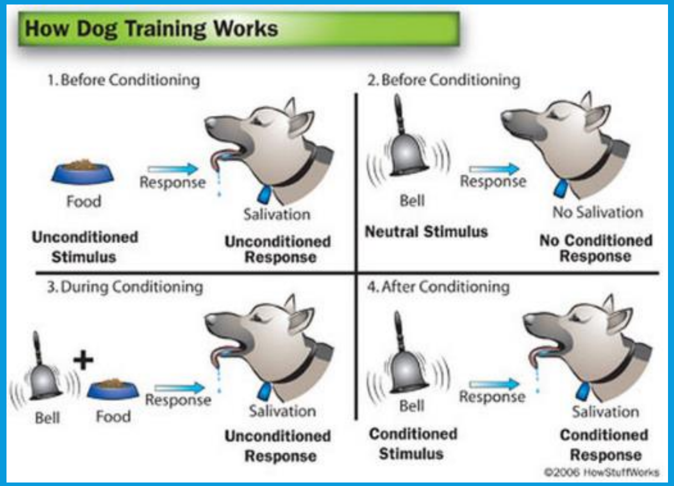

Mofan Zhou

神经网络+强化学习?

Deep Q Networks (DQN)

- Deep Q Networks (Mnih et al., 2015)
- Atari 游戏中很多比人类玩得好
- CNN + Q Learning

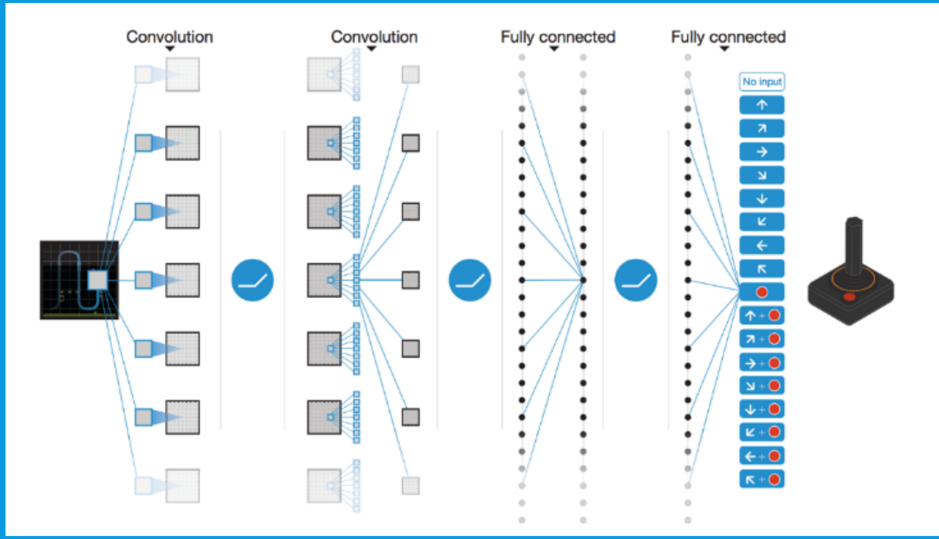

神经网络+强化学习?

Q-Learning

Q-Learning 学习过程

- 建立机器人和环境
- 循环下面的操作
  - 机器人根据现在的状态做动作
  - 这个动作会带机器人去下一个状态
  - 环境给出下一个状态和奖惩
  - 机器人学习自己动作和因果的关系
  - 下次做奖励大的动作

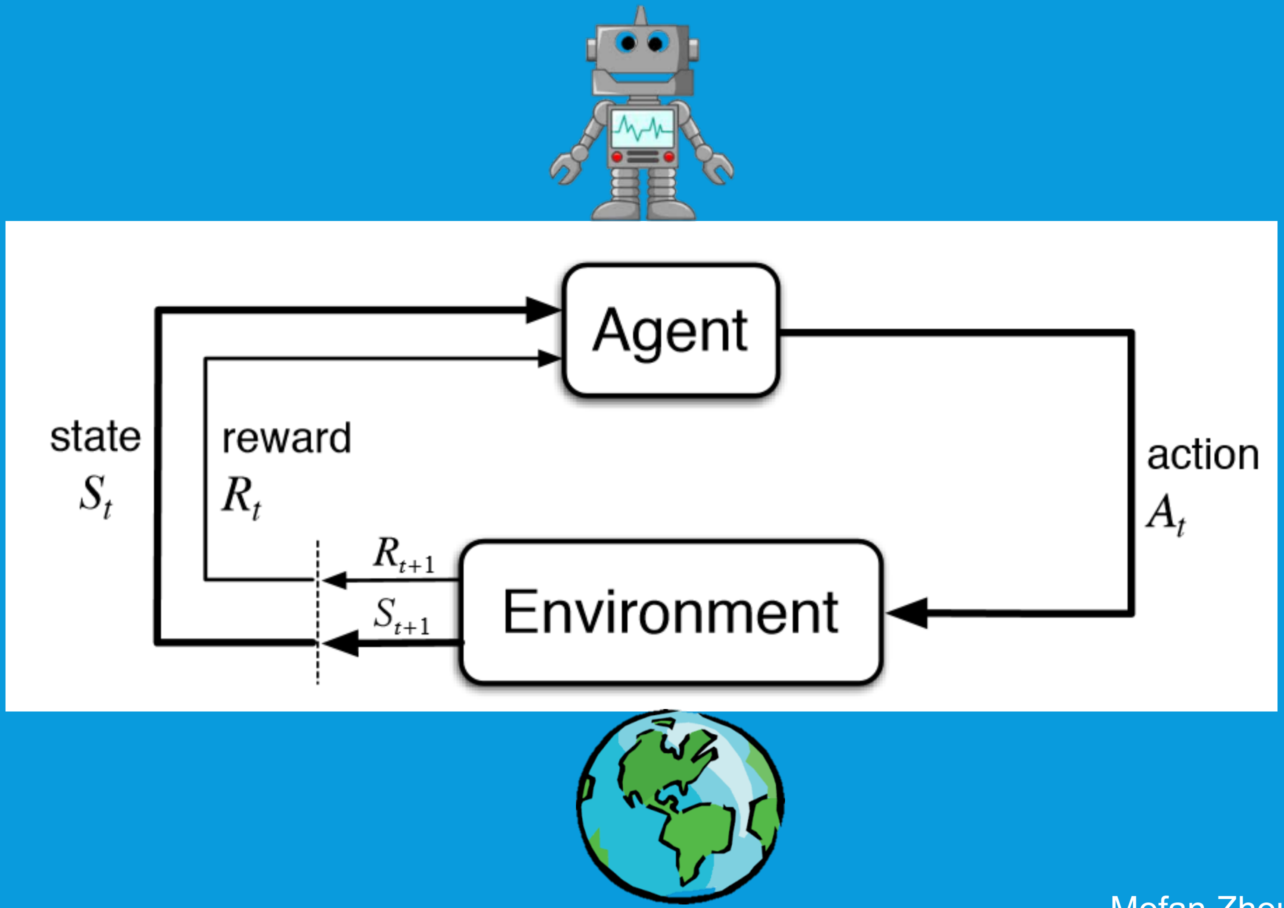

缺点: 所有记录都在表格里, 很快表格空间被用完, 无法处理复杂的问题

神经网络+强化学习?

AlphaGo

为什么以前机器下不过人类?

- 机器无法在短时间内考虑所有情况
- 机器学习能力弱

为什么 AlphaGo (Silver et al., 2016)现在可以了?

- 新算法的提出 (Monte Carlo Tree search + 神经网络)
- 计算能力提升 (GPU/TPU)

最近的 AlphaGo zero (Silver et al., 2017) 无师自通, 且学习时间更短

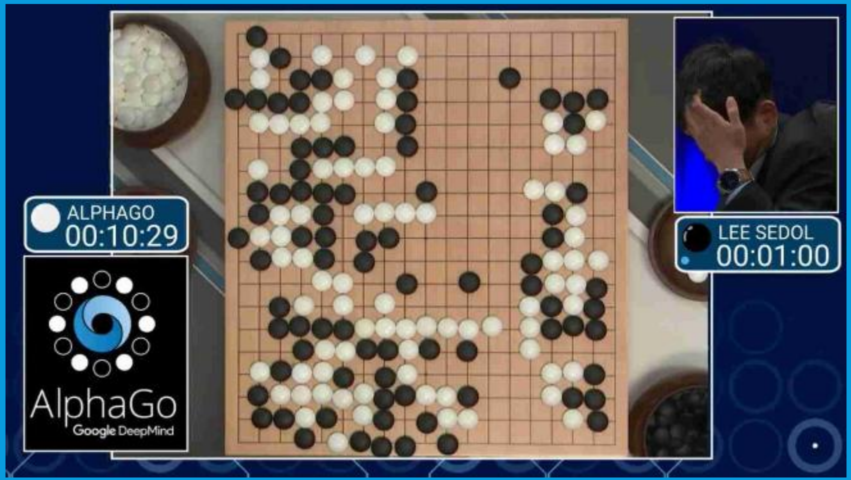

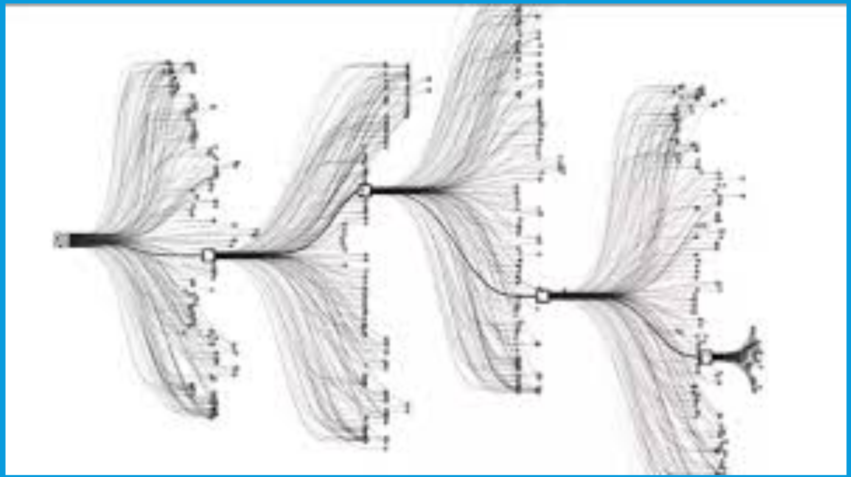

Mofan Zhou

神经网络+强化学习?

机器人模拟

两大主要领导者:

- Google DeepMind
- OpenAI

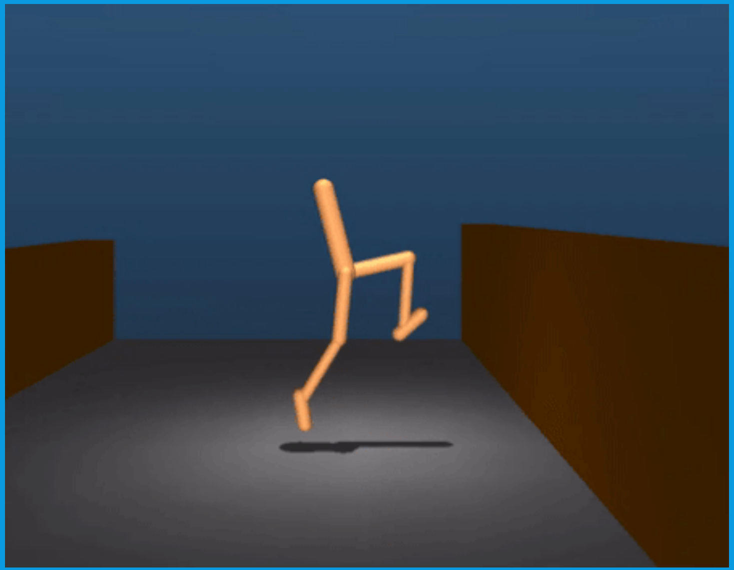

Heess et al., 2017

Schulman et al., 2017

Mofan Zhou

神经网络+强化学习?

机器人模拟

主要突破:

- 纯图片输入 (GPU). 自动驾驶算吗?
- 添加神经网络, 处理问题能力加强
- 并行运算 (A3C, DPPO)

Santana & Hotz, 2016

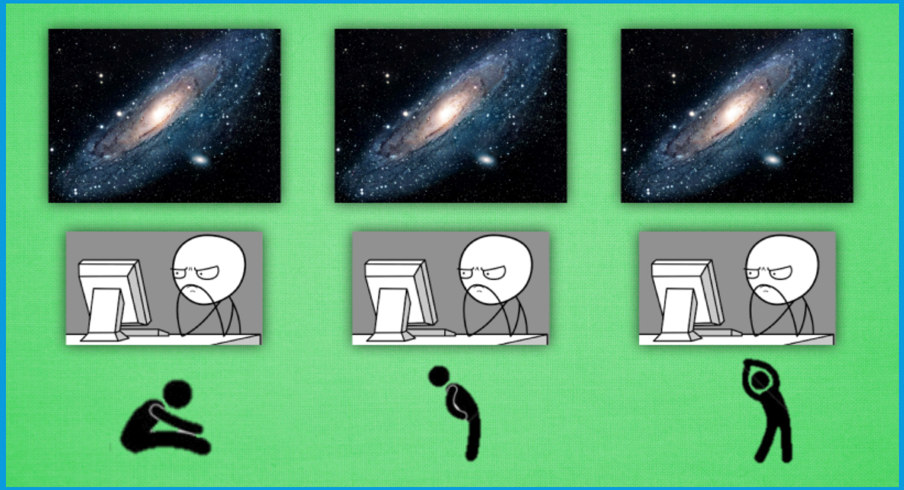

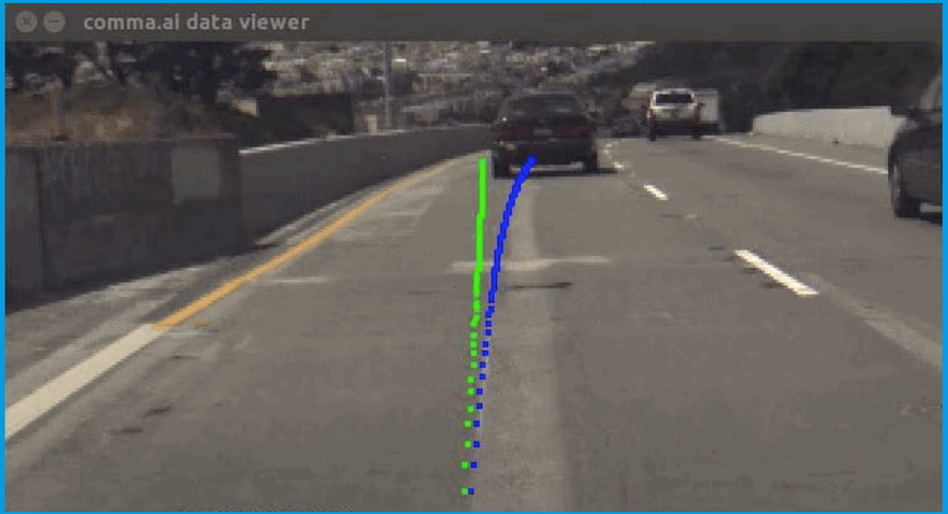

A3C 简介

神经网络+强化学习?

更多强化学习方法

- 连续动作
  - DDPG (Lillicrap et al., 2015)
  - NAF (Gu et al., 2016)
- 大规模并行
  - (Nair et al., 2015)
  - A3C (Mnih et al., 2016)
  - DPPO (Heess et al., 2017)
- 基于DQN的改进
  - 优先记忆回放 (Schaul et al., 2016)
  - Double DQN (Van Hasselt et al., 2016)
  - Duelling DQN (Wang et al., 2016)

- 模仿学习 imitation learning
  - GAN (Ho & Ermon, 2016)
  - GAN (Merel et al., 2016)
- 协同学习
  - Multiagent DDPG (Lowe et al., 2017)
  - multiagent BiCNet (Peng et al., 2017)

我做的一些简单实验 优酷视频
http://list.youku.com/albumlist/show?id=27485743&ascending=1&page=1

缺点?

深层神经网络的梯度消失/弥散问题, 学习到的东西无法顺畅传递到每一层神经层.

(一定程度上解决, LSTM, ResNet)

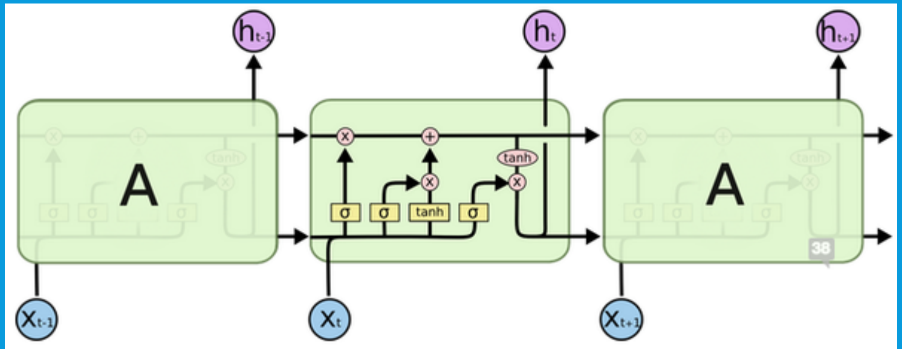

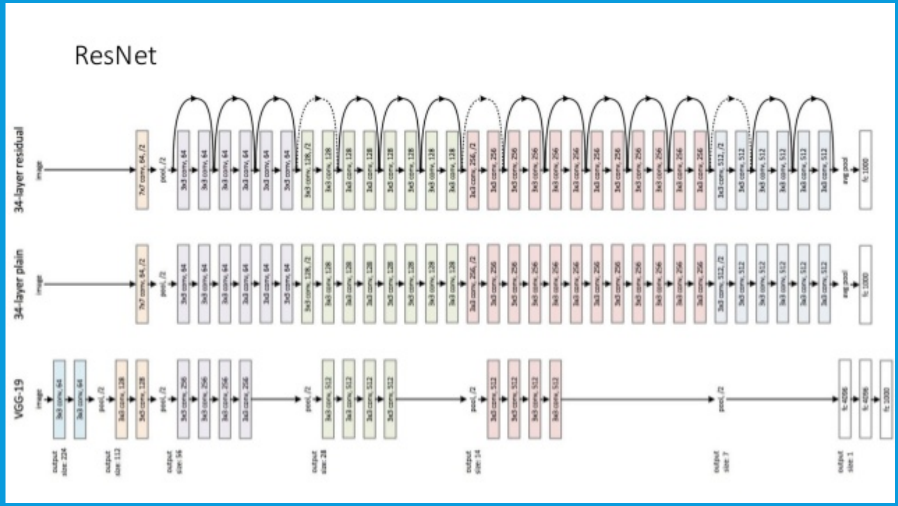

缺点?

局部最优: 梯度下降法的通病.

优化问题我们都想找到最好的, 可是往往我们只能找到相对好的. 追求完美是人类的天性. 这里还有很多上升空间. 而且这种靠反向传播的神经网络并不一定是最终形式的人工智能.

缺点?

神经网络之父 Hinton 甚至想否定自己做出贡献的反向传播算法.

抨击 CNN 的不合理性. 创建 Capsule Network (Sabour et al., 2017) 代替 CNN.

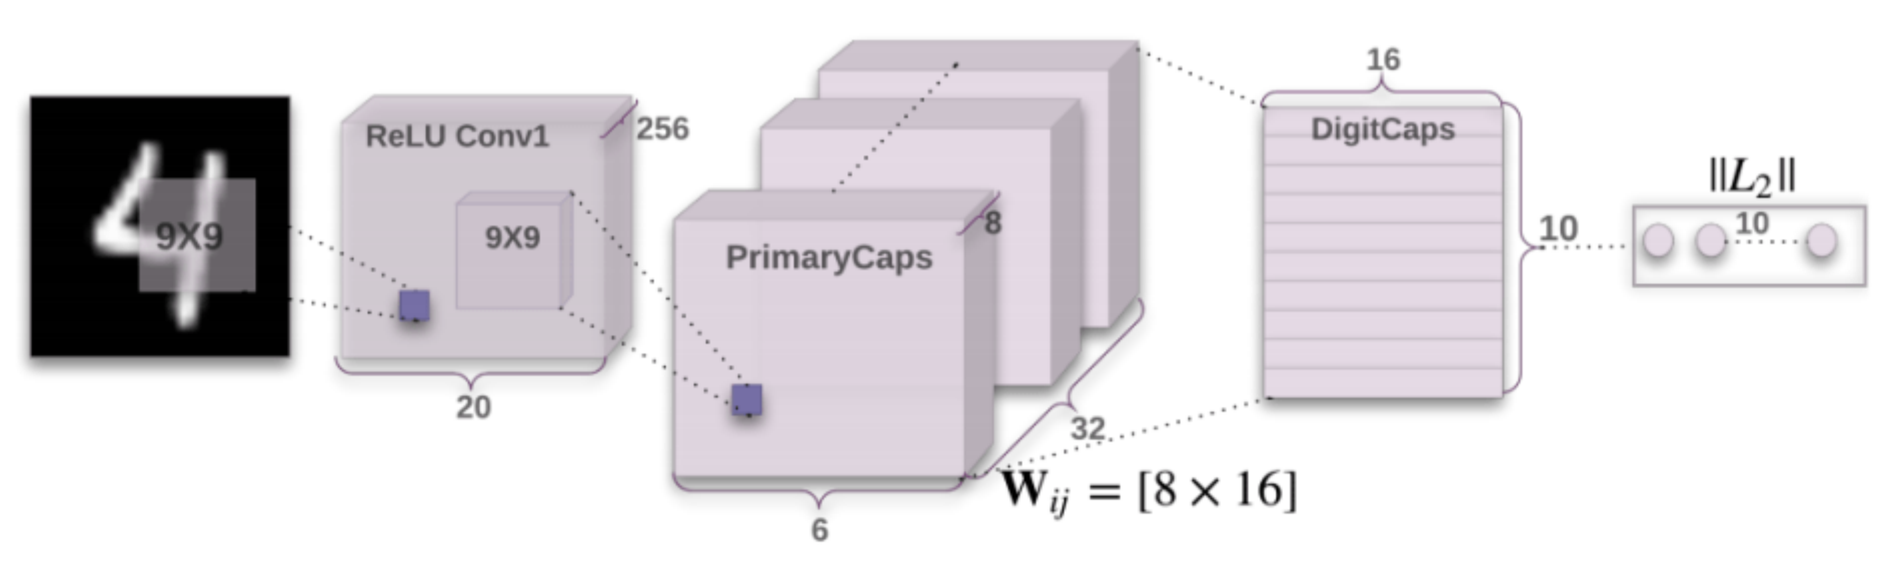

我的研究

比起我的研究，我觉得我制作的一些机器学习/神经网络简介视频更加有趣，而且更加有意义.

所以 “莫烦Python” 就是这么建立的.

为了那些 “技术宅” 们，我也分享了很多使用代码实践的教学.

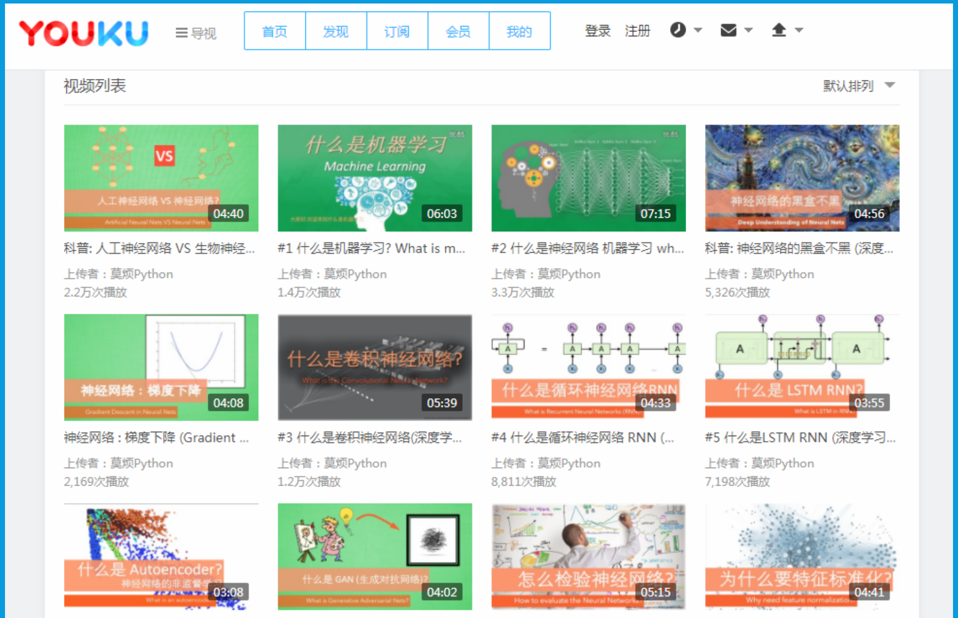

Mofan Zhou

我的研究

- 车辆行驶规则
- 智能车/车联网
- 共享道路信息

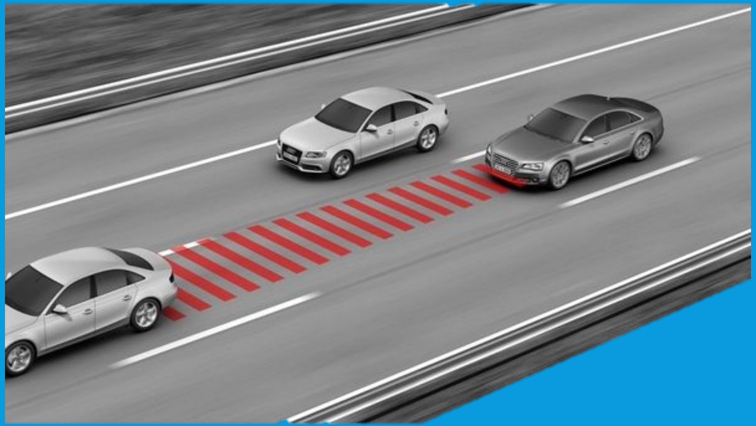

我的研究

- 模拟人类驾驶行为 (Zhou et al., 2017) /自动驾驶规则 (Zhou & Xu, 2016)
- 优化在红绿灯之中的通行效率
- 优化拥堵的交通

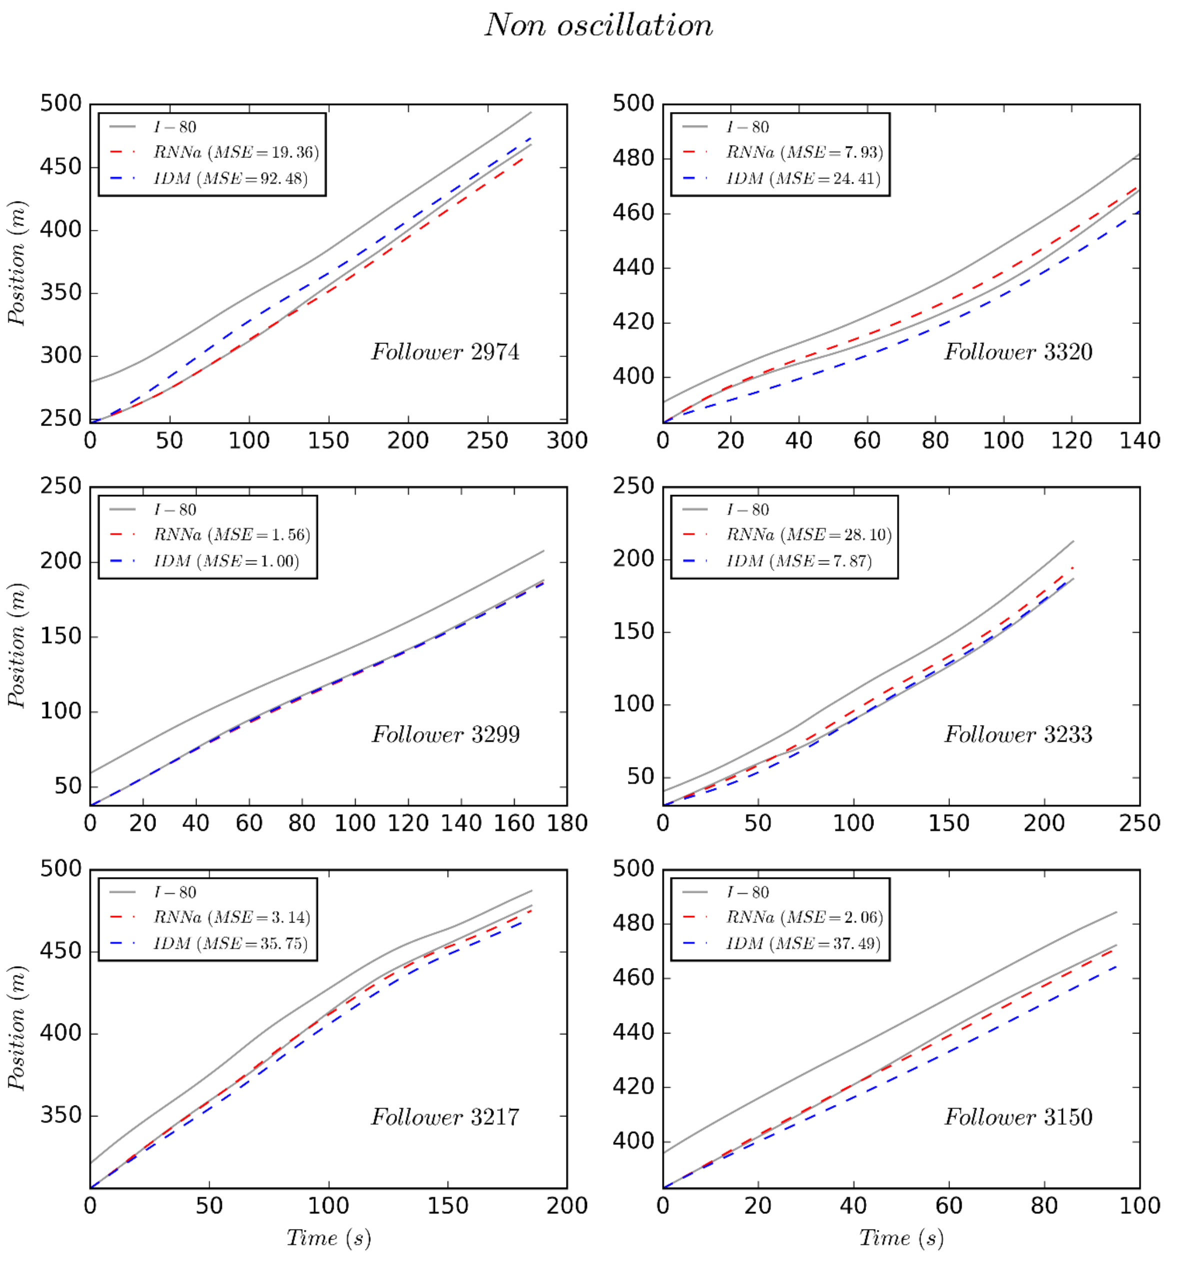

Mofan Zhou

我的研究

- 模拟人类驾驶行为 (Zhou et al., 2017) / 动驾驶规则 (Zhou & Xu, 2016)
- 优化在红绿灯之中的通行效率
- 优化拥堵的交通

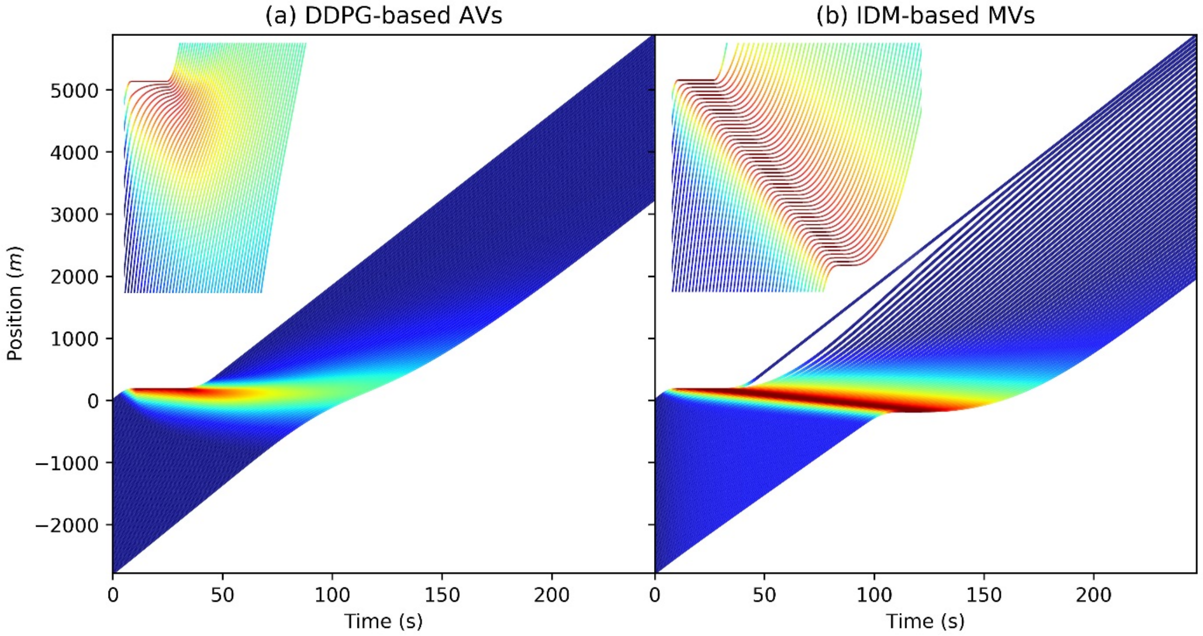

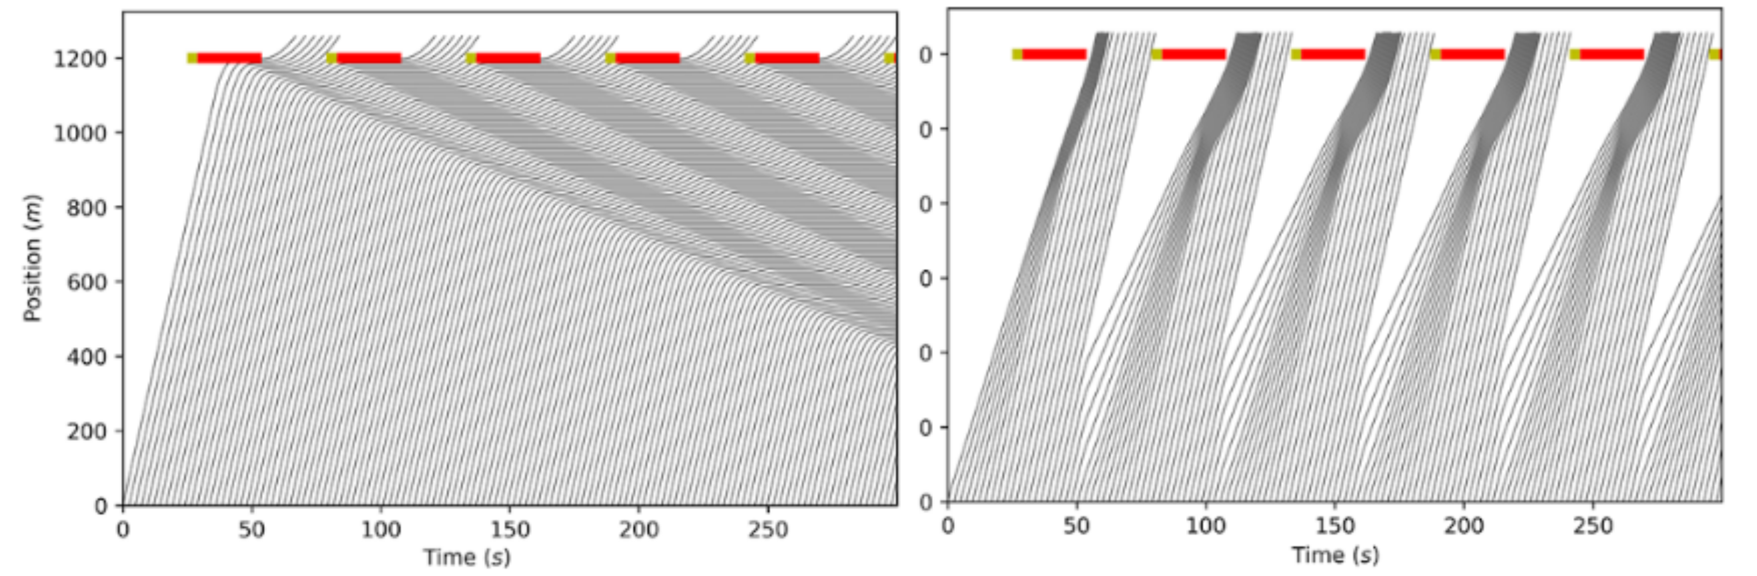

Mofan Zhou

REFERENCE

LeCun, Y., Bottou, L., Bengio, Y., and Haffner, P. (1998d). Gradient-based learning applied to document recognition. Proceedings of the IEEE, 86(11), 2278–2324.

Simonyan, K. and Zisserman, A., 2014. Very deep convolutional networks for large-scale image recognition. *arXiv preprint arXiv:1409.1556*.

Szegedy, C., Liu, W., Jia, Y., Sermanet, P., Reed, S., Anguelov, D., Erhan, D., Vanhoucke, V. and Rabinovich, A., 2015. Going deeper with convolutions. In *Proceedings of the IEEE conference on computer vision and pattern recognition* (pp. 1-9).

He, K., Zhang, X., Ren, S. and Sun, J., 2016. Deep residual learning for image recognition. In *Proceedings of the IEEE conference on computer vision and pattern recognition* (pp. 770-778).

Girshick, R. Fast r-cnn. Proceedings of the IEEE International Conference on Computer Vision, 2015. 1440-1448.

Ren, S., He, K., Girshick, R. & Sun, J. Faster r-cnn: Towards real-time object detection with region proposal networks. Advances in neural information processing systems, 2015. 91-99.

Hochreiter, S. & Schmidhuber, J. 1997. Long short-term memory. *Neural computation,* 9**,** 1735-1780.

Cho, K., Van Merriënboer, B., Gulcehre, C., Bahdanau, D., Bougares, F., Schwenk, H. & Bengio, Y. 2014. Learning phrase representations using RNN encoder-decoder for statistical machine translation. *ArXiv e-prints* [Online], 1406. Available: https://arxiv.org/abs/1406.1078v3.

REFERENCE

Goodfellow, I. J., Pouget-Abadie, J., Mirza, M., Xu, B., Warde-Farley, D., Ozair, S., Courville, A. & Bengio, Y. 2014. Generative Adversarial Networks. *ArXiv e-prints* [Online], 1406. Available: https://arxiv.org/abs/1406.2661.

Zhang, H., Xu, T., Li, H., Zhang, S., Huang, X., Wang, X. and Metaxas, D., 2016. Stackgan: Text to photo-realistic image synthesis with stacked generative adversarial networks. *arXiv preprint arXiv:1612.03242*.

Zhang, R., Isola, P. and Efros, A.A., 2016, October. Colorful image colorization. In *European Conference on Computer Vision* (pp. 649-666). Springer International Publishing.

Radford, A., Metz, L. and Chintala, S., 2015. Unsupervised representation learning with deep convolutional generative adversarial networks. *arXiv preprint arXiv:1511.06434*.

Dahl, R., Norouzi, M. and Shlens, J., 2017. Pixel recursive super resolution. *arXiv preprint arXiv:1702.00783*.

Mnih, V., Kavukcuoglu, K., Silver, D., Rusu, A. A., Veness, J., Bellemare, M. G., Graves, A., Riedmiller, M., Fidjeland, A. K. & Ostrovski, G. 2015. Human-level control through deep reinforcement learning. *Nature,* 518, 529-533.

Silver, D., Huang, A., Maddison, C. J., Guez, A., Sifre, L., van den Driessche, G., Schrittwieser, J., Antonoglou, I., Panneershelvam, V., Lanctot, M., Dieleman, S., Grewe, D., Nham, J., Kalchbrenner, N., Sutskever, I., Lillicrap, T., Leach, M., Kavukcuoglu, K., Graepel, T. & Hassabis, D. 2016. Mastering the game of Go with deep neural networks and tree search. *Nature,* 529, 484-489.

REFERENCE

Silver, D., Schrittwieser, J., Simonyan, K., Antonoglou, I., Huang, A., Guez, A., Hubert, T., Baker, L., Lai, M., Bolton, A., Chen, Y., Lillicrap, T., Hui, F., Sifre, L., van den Driessche, G., Graepel, T. & Hassabis, D. 2017. Mastering the game of Go without human knowledge. *Nature,* 550, 354-359.

Heess, N., TB, D., Sriram, S., Lemmon, J., Merel, J., Wayne, G., Tassa, Y., Erez, T., Wang, Z., Eslami, S. M. A., Riedmiller, M. & Silver, D. 2017. Emergence of Locomotion Behaviours in Rich Environments. *ArXiv e-prints* [Online], 1707. Available: https://arxiv.org/abs/1707.02286.

Schulman, J., Wolski, F., Dhariwal, P., Radford, A. & Klimov, O. 2017. Proximal Policy Optimization Algorithms. *ArXiv e-prints* [Online], 1707. Available: https://arxiv.org/abs/1707.06347.

Santana, E. & Hotz, G. 2016. Learning a Driving Simulator. *ArXiv e-prints* [Online], 1608. Available: https://arxiv.org/abs/1608.01230.

Lillicrap, T. P., Hunt, J. J., Pritzel, A., Heess, N., Erez, T., Tassa, Y., Silver, D. & Wierstra, D. 2015. Continuous control with deep reinforcement learning. *ArXiv e-prints* [Online], 1509. Available: https://arxiv.org/abs/1509.02971.

Gu, S., Lillicrap, T., Sutskever, I. & Levine, S. 2016. Continuous Deep Q-Learning with Model-based Acceleration. *ArXiv e-prints* [Online], 1603. Available: https://arxiv.org/abs/1603.00748.

REFERENCE

Nair, A., Srinivasan, P., Blackwell, S., Alcicek, C., Fearon, R., De Maria, A., Panneershelvam, V., Suleyman, M., Beattie, C., Petersen, S., Legg, S., Mnih, V., Kavukcuoglu, K. & Silver, D. 2015. Massively Parallel Methods for Deep Reinforcement Learning. *ArXiv e-prints* [Online], 1507. Available: https://arxiv.org/abs/1507.04296.

Mnih, V., Badia, A. P., Mirza, M., Graves, A., Lillicrap, T. P., Harley, T., Silver, D. & Kavukcuoglu, K. Asynchronous methods for deep reinforcement learning. International Conference on Machine Learning, 2016.

Heess, N., TB, D., Sriram, S., Lemmon, J., Merel, J., Wayne, G., Tassa, Y., Erez, T., Wang, Z., Eslami, S. M. A., Riedmiller, M. & Silver, D. 2017. Emergence of Locomotion Behaviours in Rich Environments. *ArXiv e-prints* [Online], 1707. Available: https://arxiv.org/abs/1707.02286.

Schaul, T., Quan, J., Antonoglou, I. & Silver, D. 2016. Prioritized Experience Replay. *ICLR.*

Van Hasselt, H., Guez, A. & Silver, D. Deep Reinforcement Learning with Double Q-Learning. AAAI, 2016. 2094-2100.

Wang, Z., Schaul, T., Hessel, M., van Hasselt, H., Lanctot, M. & de Freitas, N. Dueling Network Architectures for Deep Reinforcement Learning. ICML, 2016. 1995–2003.

Hester, T., Vecerik, M., Pietquin, O., Lanctot, M., Schaul, T., Piot, B., Sendonaris, A., Dulac-Arnold, G., Osband, I., Agapiou, J., Leibo, J. Z. & Gruslys, A. 2017. Learning from Demonstrations for Real World Reinforcement Learning. *ArXiv e-prints* [Online], 1704. Available: https://arxiv.org/abs/1704.03732.

Ho, J. & Ermon, S. Generative adversarial imitation learning. Advances in Neural Information Processing Systems, 2016. 4565-4573.

Merel, J., Tassa, Y., TB, D., Srinivasan, S., Lemmon, J., Wang, Z., Wayne, G. & Heess, N. 2017. Learning human behaviors from motion capture by adversarial imitation. *ArXiv e-prints* [Online], 1707. Available: https://arxiv.org/abs/1707.02201v2.

REFERENCE

Lowe, R., Wu, Y., Tamar, A., Harb, J., Abbeel, P. & Mordatch, I. 2017. Multi-Agent Actor-Critic for Mixed Cooperative-Competitive Environments. *ArXiv e-prints* [Online], 1706. Available: https://arxiv.org/abs/1706.02275v2.

Peng, P., Yuan, Q., Wen, Y., Yang, Y., Tang, Z., Long, H. & Wang, J. 2017. Multiagent Bidirectionally-Coordinated Nets for Learning to Play StarCraft Combat Games. *ArXiv e-prints* [Online], 1703. Available: https://arxiv.org/abs/1703.10069.

Sara Sabour, Nicholas Frosst & Hinton, G. E. 2017. Dynamic Routing Between Capsules. *ArXiv e-prints* [Online], 1710. Available: https://arxiv.org/abs/1710.09829.

Zhou, M., Qu, X. & Li, X. 2017. A recurrent neural network based microscopic car following model to predict traffic oscillation. *Transportation Research Part C: Emerging Technologies,* 84, 245-264.

Zhou, M. & Qu, X. 2016. Microscopic Car-Following Model for Autonomous Vehicles Using Reinforcement Learning. *Symposium on Innovations in Traffic Flow Theory and Characteristics and TFT Midyear Meeting.*